Análise e Projeto de Algoritmos

Algoritmos Gulosos

Algoritmo de Huffman

Gilberto Farias de Sousa Filho

História

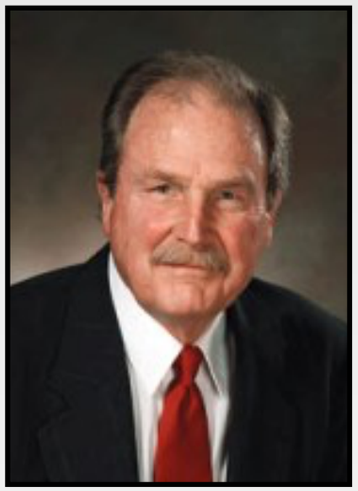

- Criado em 1951 por David Albert Huffman.

- Foi dada a opção de estudar para a prova final ou elaborar um trabalho acadêmico.

  - Qual a forma mais eficiente de representar símbolos através de códigos binários ?

Motivações

- Compressão de Dados
  - Salvar Espaço de Armazenamento
    - Agilizar comunicação de informação
- Machine Learning (Clusterização de Textos)

Regras do Jogo

- Dados são representados através de sequências de bits (bitstreams).

- Sequências de bits podem ser visualizadas através de sequências de bytes (bytestreams).

- O objetivo é comprimir bytestreams **sem** ter **perda de informação** na hora da descompressão.

Modelo Básico

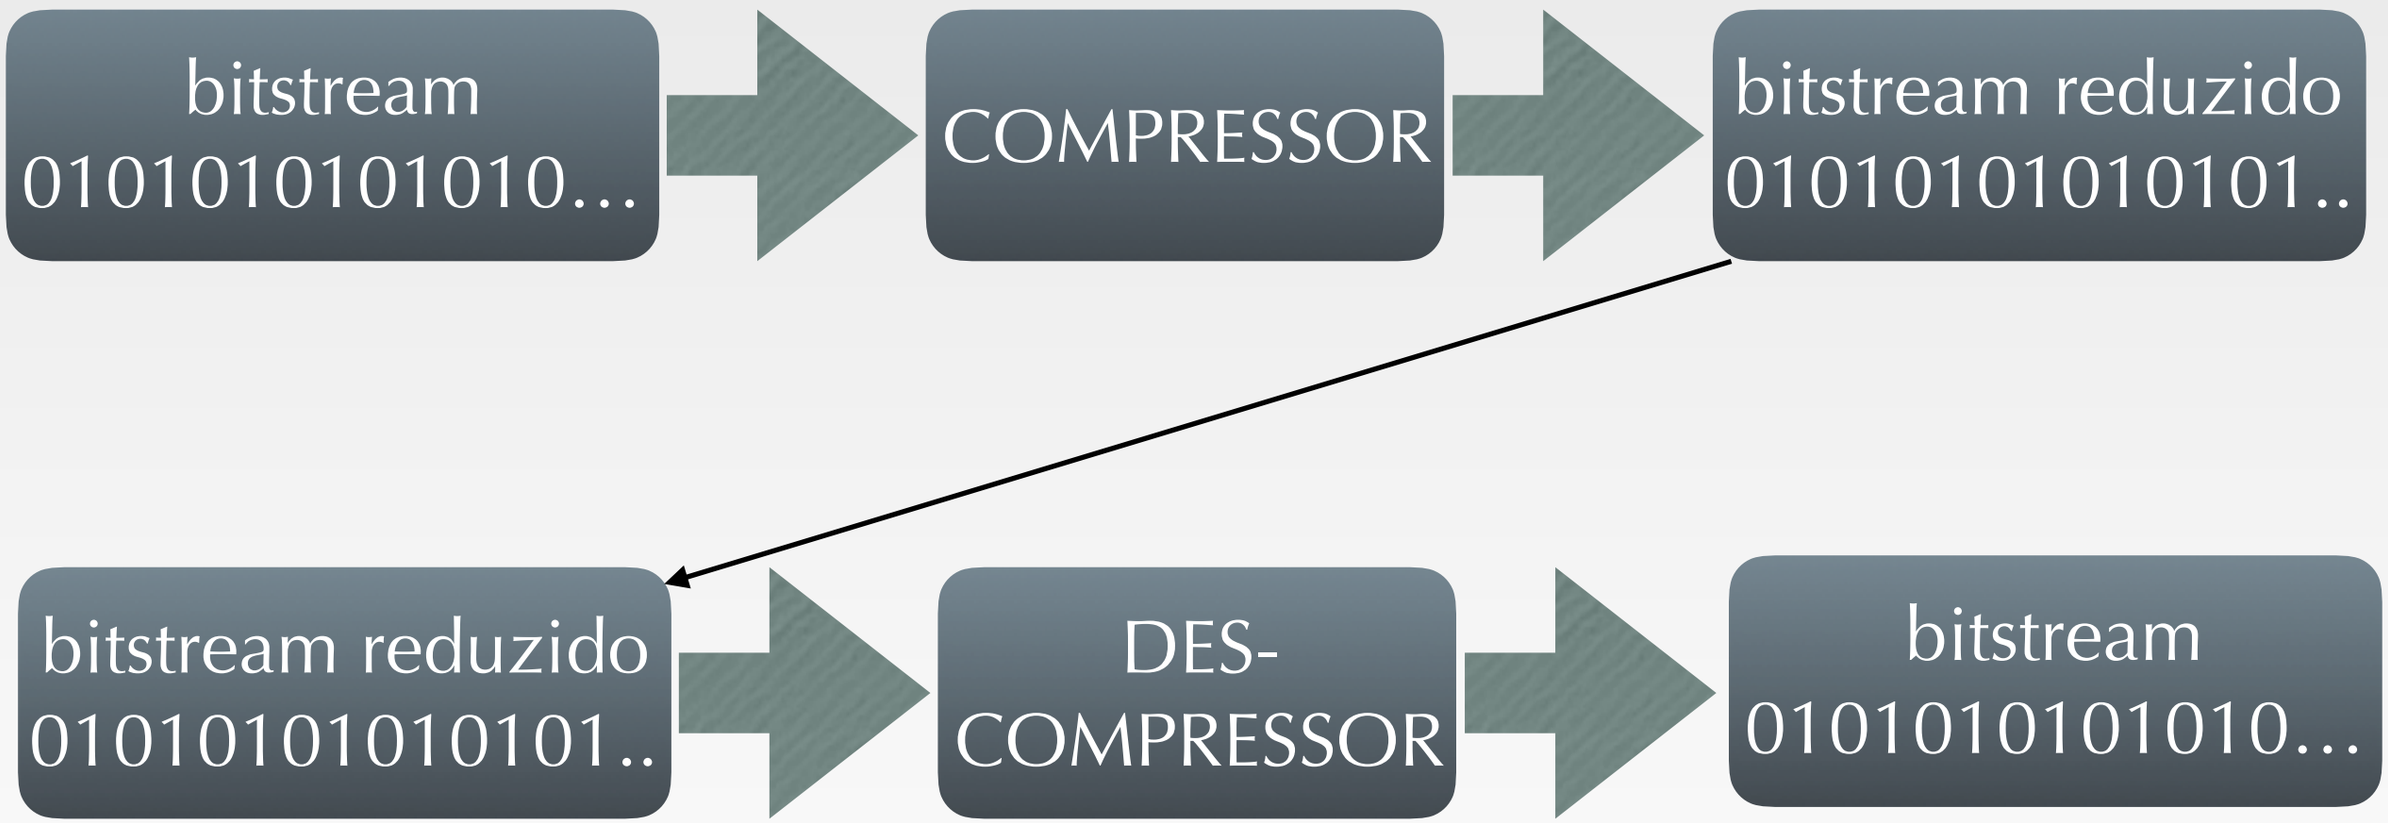

Compressão Estatística

- Bytes não possuem mesma frequência de ocorrência em certos tipos de arquivos (Texto, imagens ...). Mesmo assim, eles possuem mesma quantidade de bits.
  - Ex: chars ASCII têm 1 byte. Seja esse char <**e**> ou <**~**>
- A ideia da compressão estatística é atribuir codificações binárias de tamanho variável para representar bytes.

Codificação Binária

- Considere tabela de codificação binária para chars ASCII ao lado.
- Através dela o texto <iaaoa> pode ser codificado como <100101101110101>.
- Entretanto, existem duas decodificações diferentes. <iaaoa> ou <iaaeu>.
- Por que isso acontece ?

Byte	Código
a	101
e	11
i	100
o	110
u	0101

Codificação Binária

- O problema de ambiguidade na decodificação ocorre quando existe um código que é prefixo de outro código.

Byte	Código
a	101
e	11
i	100
o	110
u	0101

Codificação de Prefixo

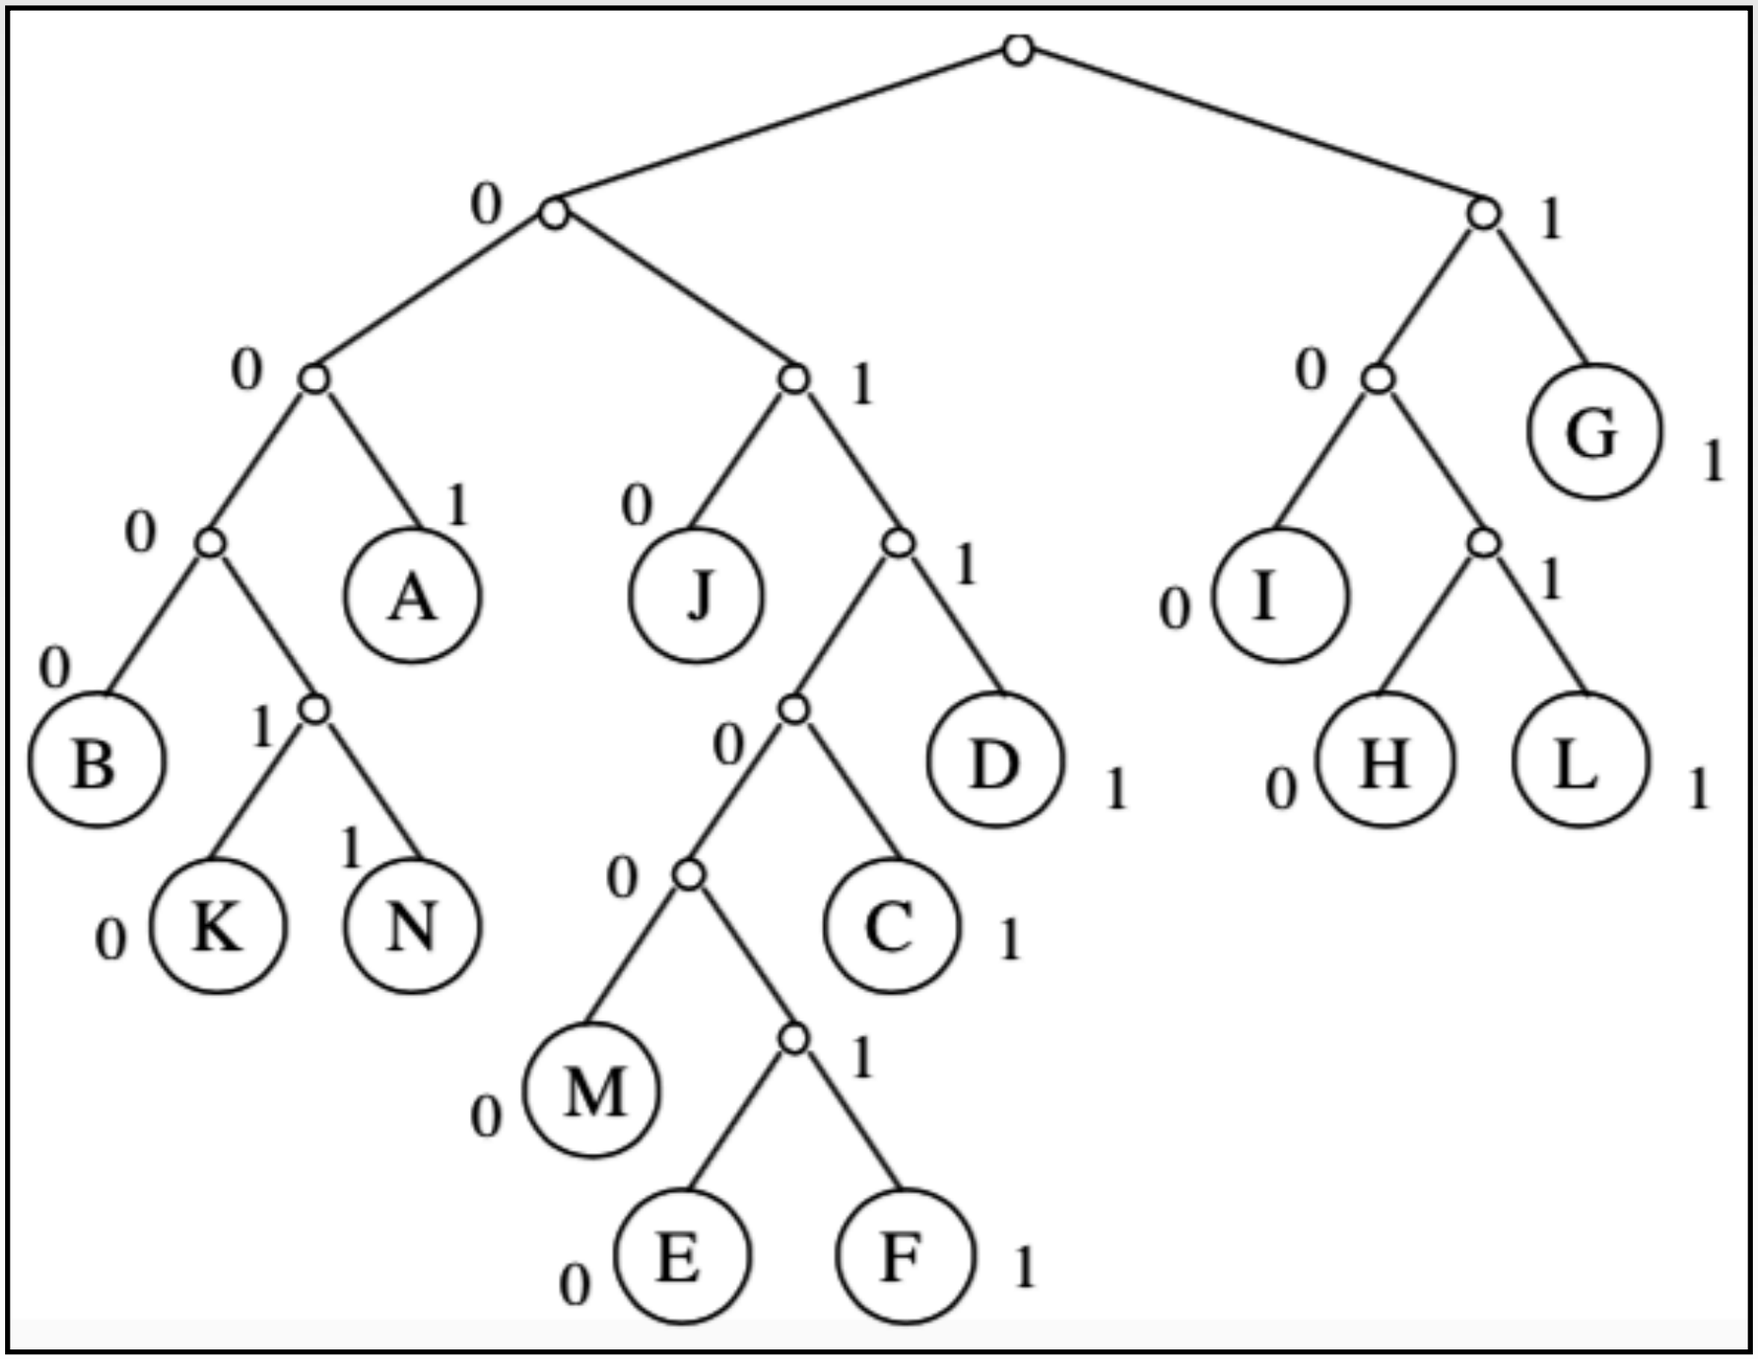

Codificação de Prefixo

- Como fazer para gerar uma codificação que seja a menor possível ?

- Formalmente, seja A o alfabeto do bytestream a ser codificado. O problema consiste em:

$$min \sum n_i c_i$$

- Onde *ni* e *ci* representam, respectivamente, a frequência e codificação de um byte *ai* de *A*.

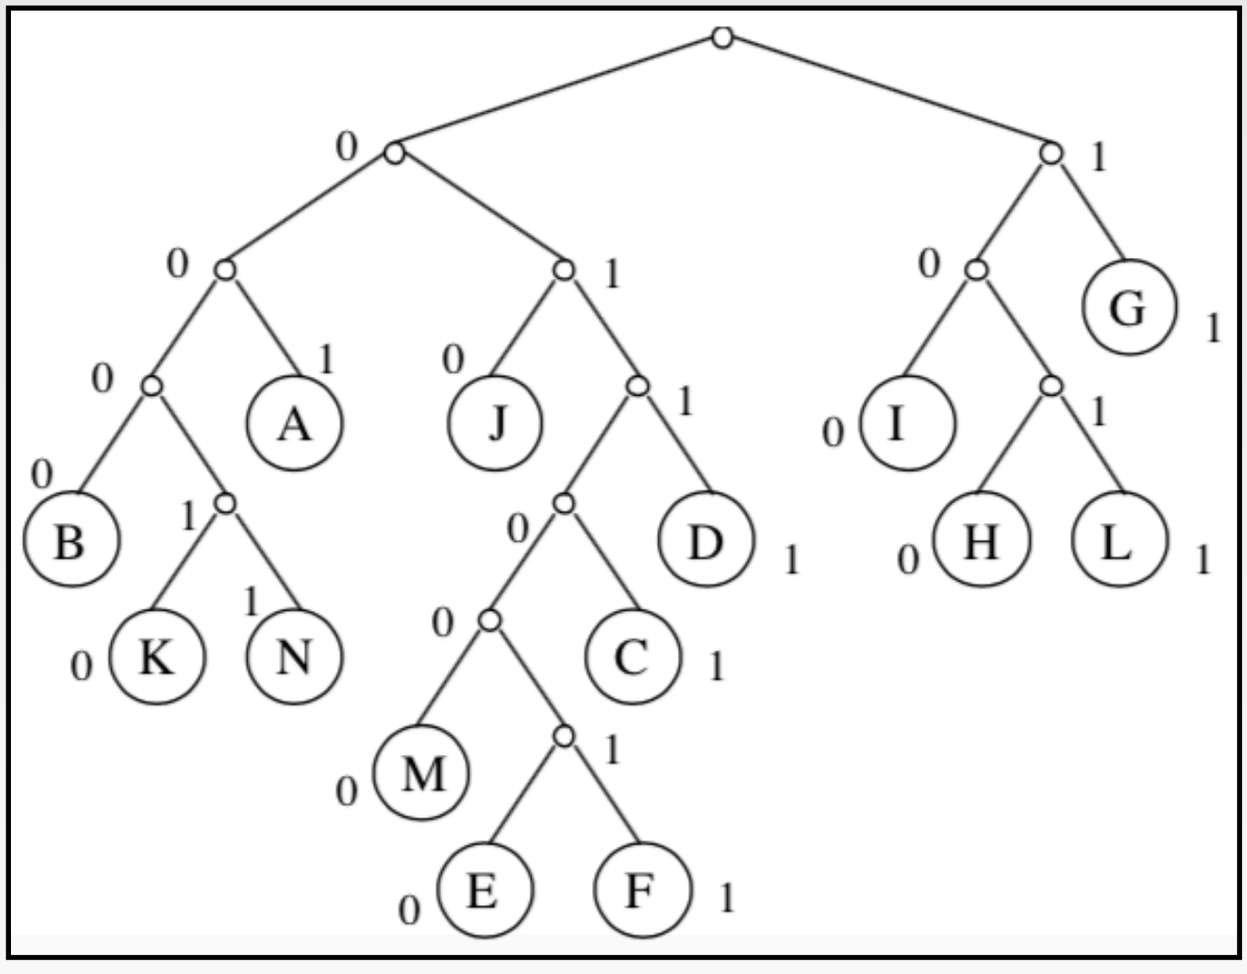

Codificação Binária de Huffman

- O algoritmo de Huffman realiza compressão estatística.
- O algoritmo de Huffman é o melhor gerador de codificações inteiras possível.
- O algoritmo de codificação de Huffman associa uma árvore a cada byte. Inicialmente, cada árvore possui um único nó, com peso igual à probabilidade de ocorrência do byte a ela associado. A cada iteração do algoritmo, as duas árvores de menor peso são substituídas por uma nova árvore cujo peso é a soma dos seus pesos. O procedimento termina quando resta apenas uma única árvore.

Árvore de Huffman

File :

b	p	`	m	j	o	d	a	i	r	u	l	s	e	
1	1	2	2	3	3	3	4	4	5	5	6	6	8	12

Árvore de Huffman

File :

b	p	`	m	j	o	d	a	i	r	u	l	s	e	
1	1	2	2	3	3	3	4	4	5	5	6	6	8	12

Árvore de Huffman

File :

`	m	j	o	d	a	i	r	u	l	s	e	
2	2	3	3	3	4	4	5	5	6	6	8	12

Árvore de Huffman

File :

`	m	j	o	d	a	i	r	u	l	s	e	
2	2	3	3	3	4	4	5	5	6	6	8	12

Árvore de Huffman

File :

j	o	d	a	i	r	u	l	s	e	
3	3	3	4	4	5	5	6	6	8	12

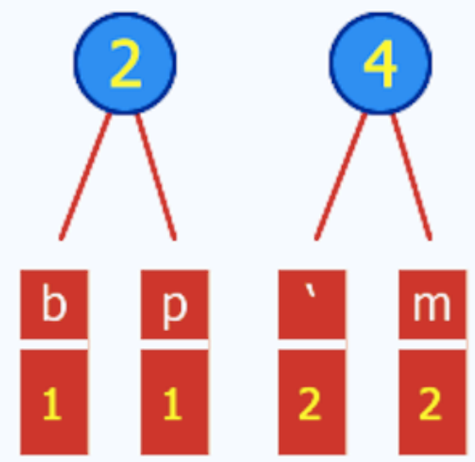

Árvore de Huffman

File :

j	o	d	a	i	r	u	l	s	e	
3	3	3	4	4	5	5	6	6	8	12

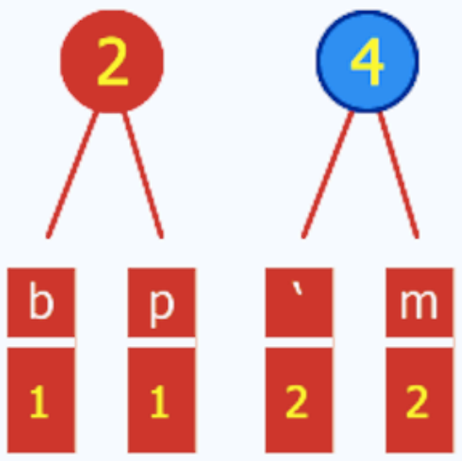

Árvore de Huffman

File :

o	d	a	i	r	u	l	s	e	
3	3	4	4	5	5	6	6	8	12

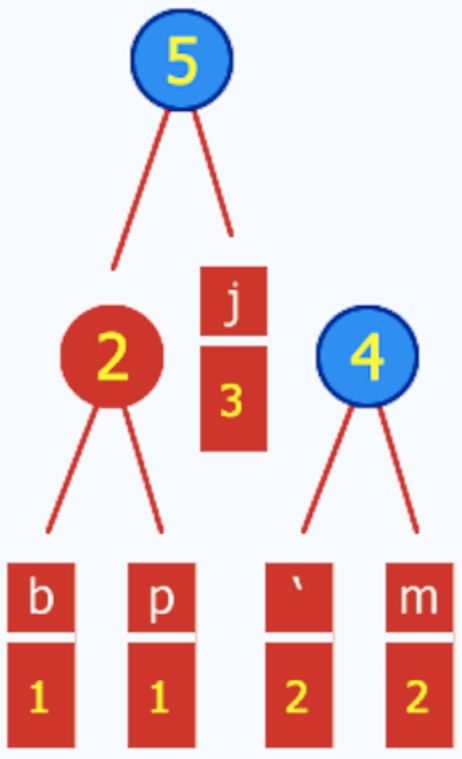

Árvore de Huffman

File :

o	d	a	i	r	u	l	s	e	
3	3	4	4	5	5	6	6	8	12

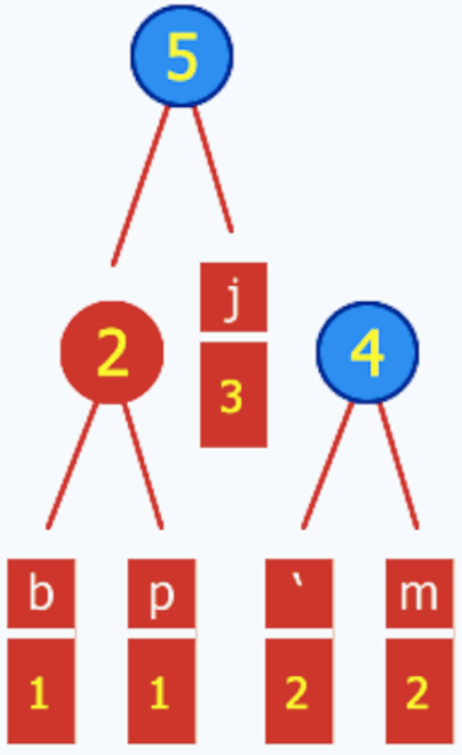

Árvore de Huffman

File :

a	i	r	u	l	s	e	
4	4	5	5	6	6	8	12

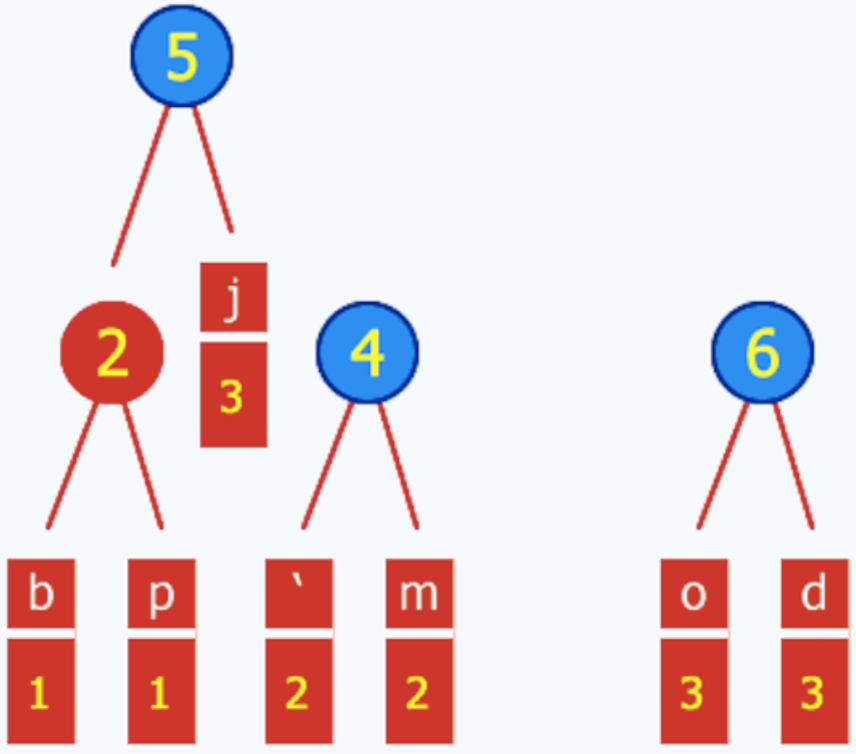

Árvore de Huffman

File :

a	i	r	u	l	s	e	
4	4	5	5	6	6	8	12

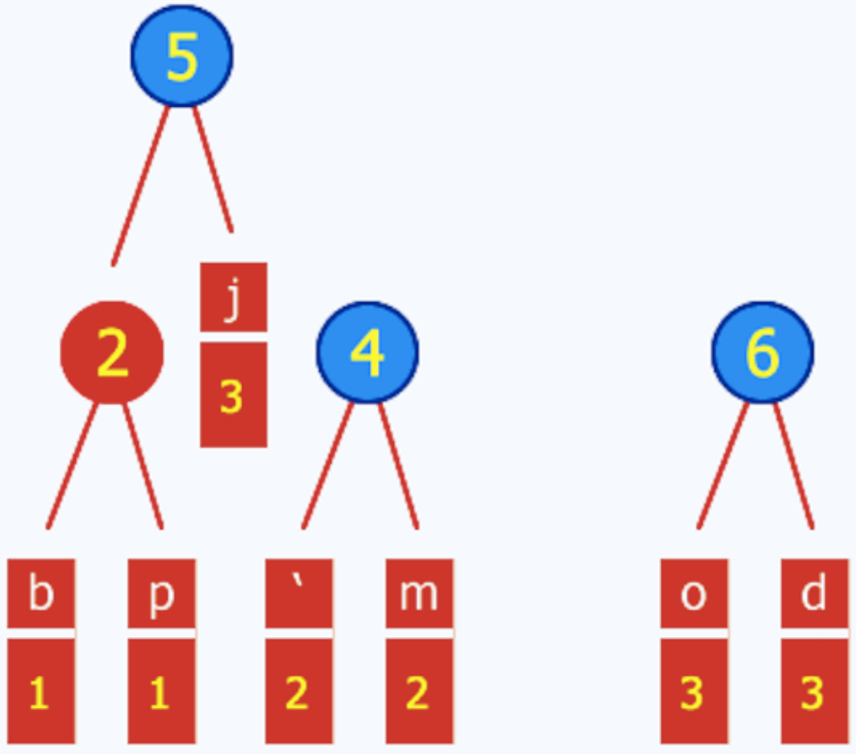

Árvore de Huffman

File :

r	u	l	s	e	
5	5	6	6	8	12

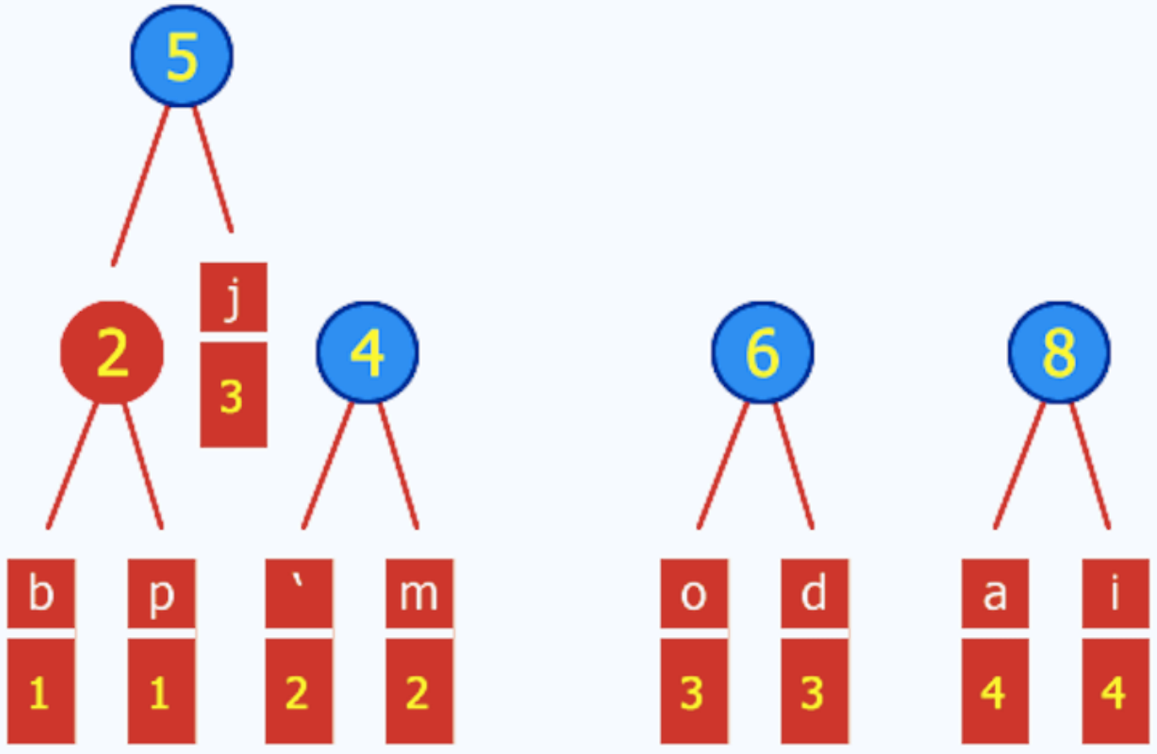

Árvore de Huffman

File :

r	u	l	s	e	
5	5	6	6	8	12

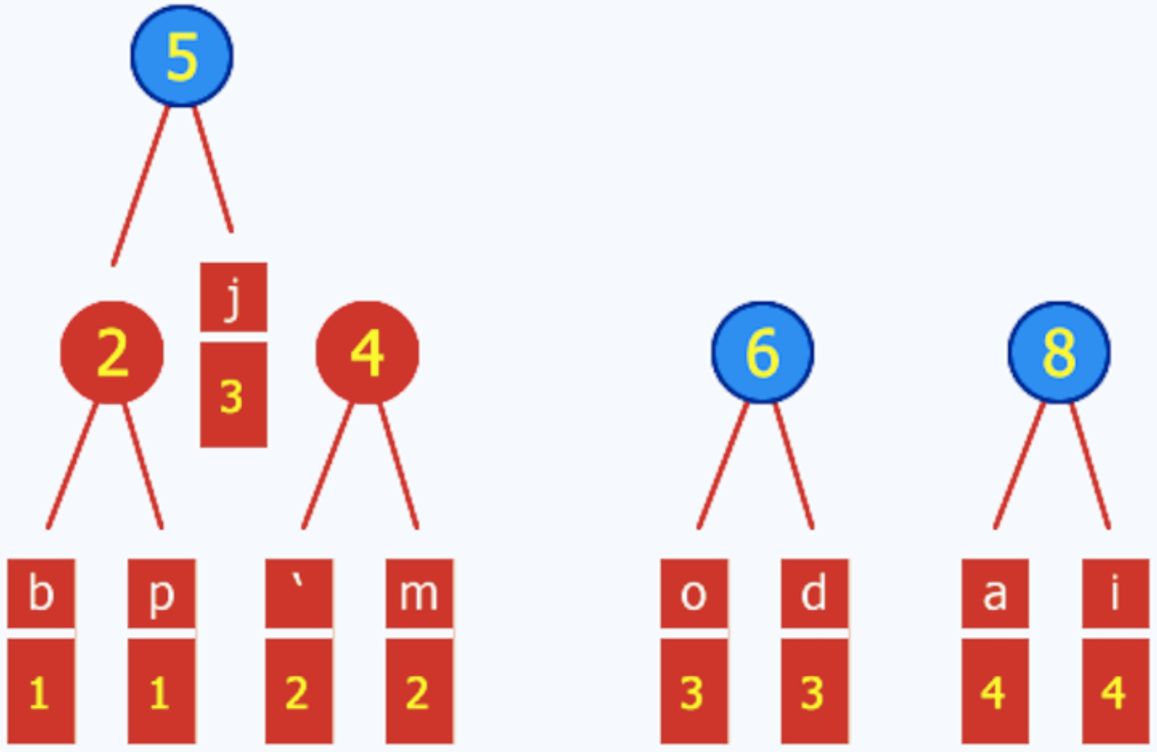

Árvore de Huffman

File :

u	l	s	e	
5	6	6	8	12

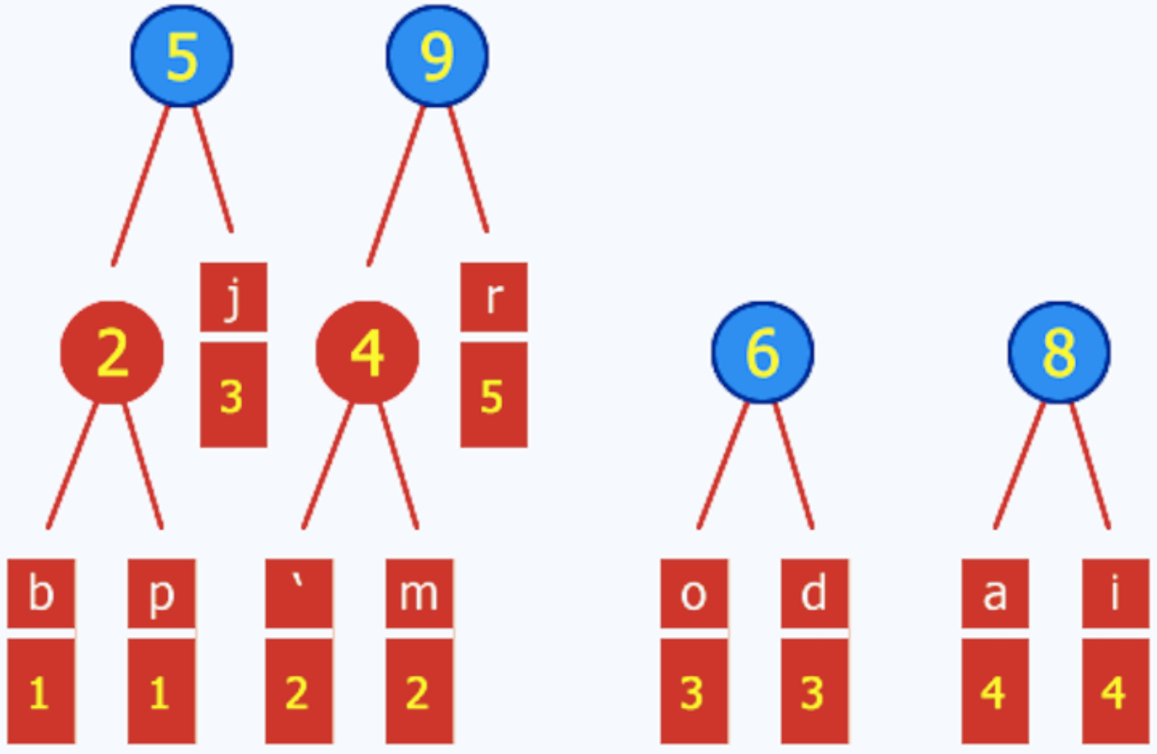

Árvore de Huffman

File :

u	l	s	e	
5	6	6	8	12

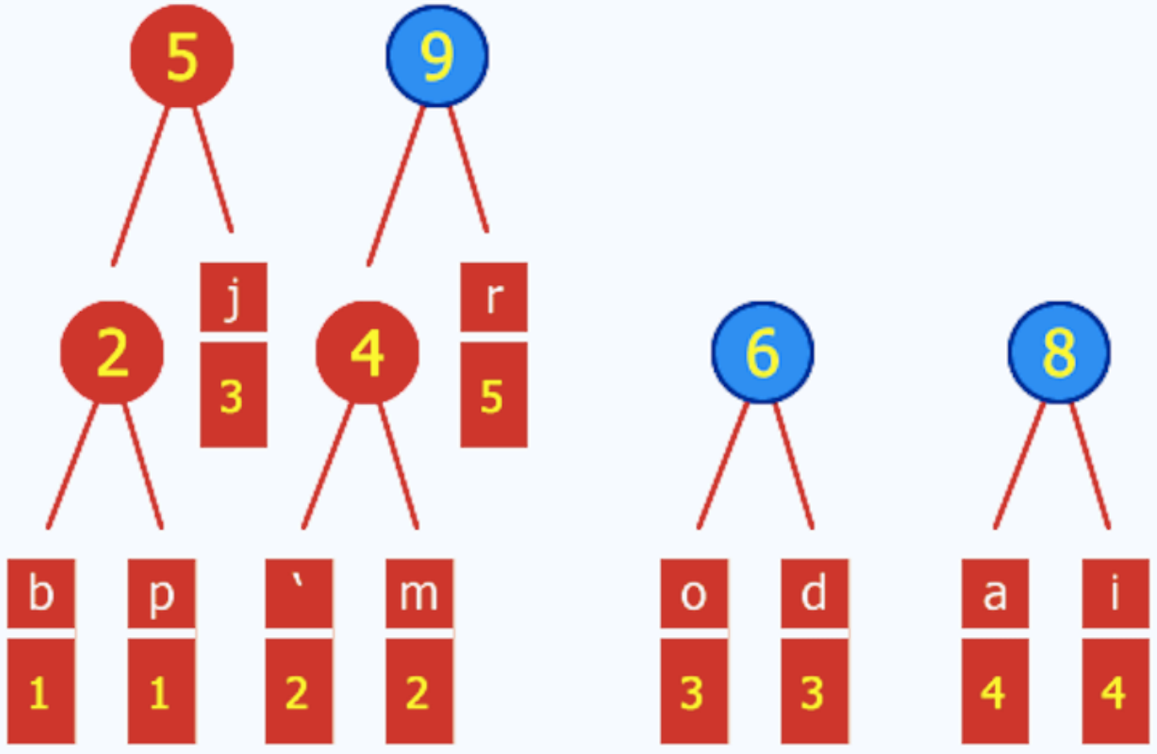

Árvore de Huffman

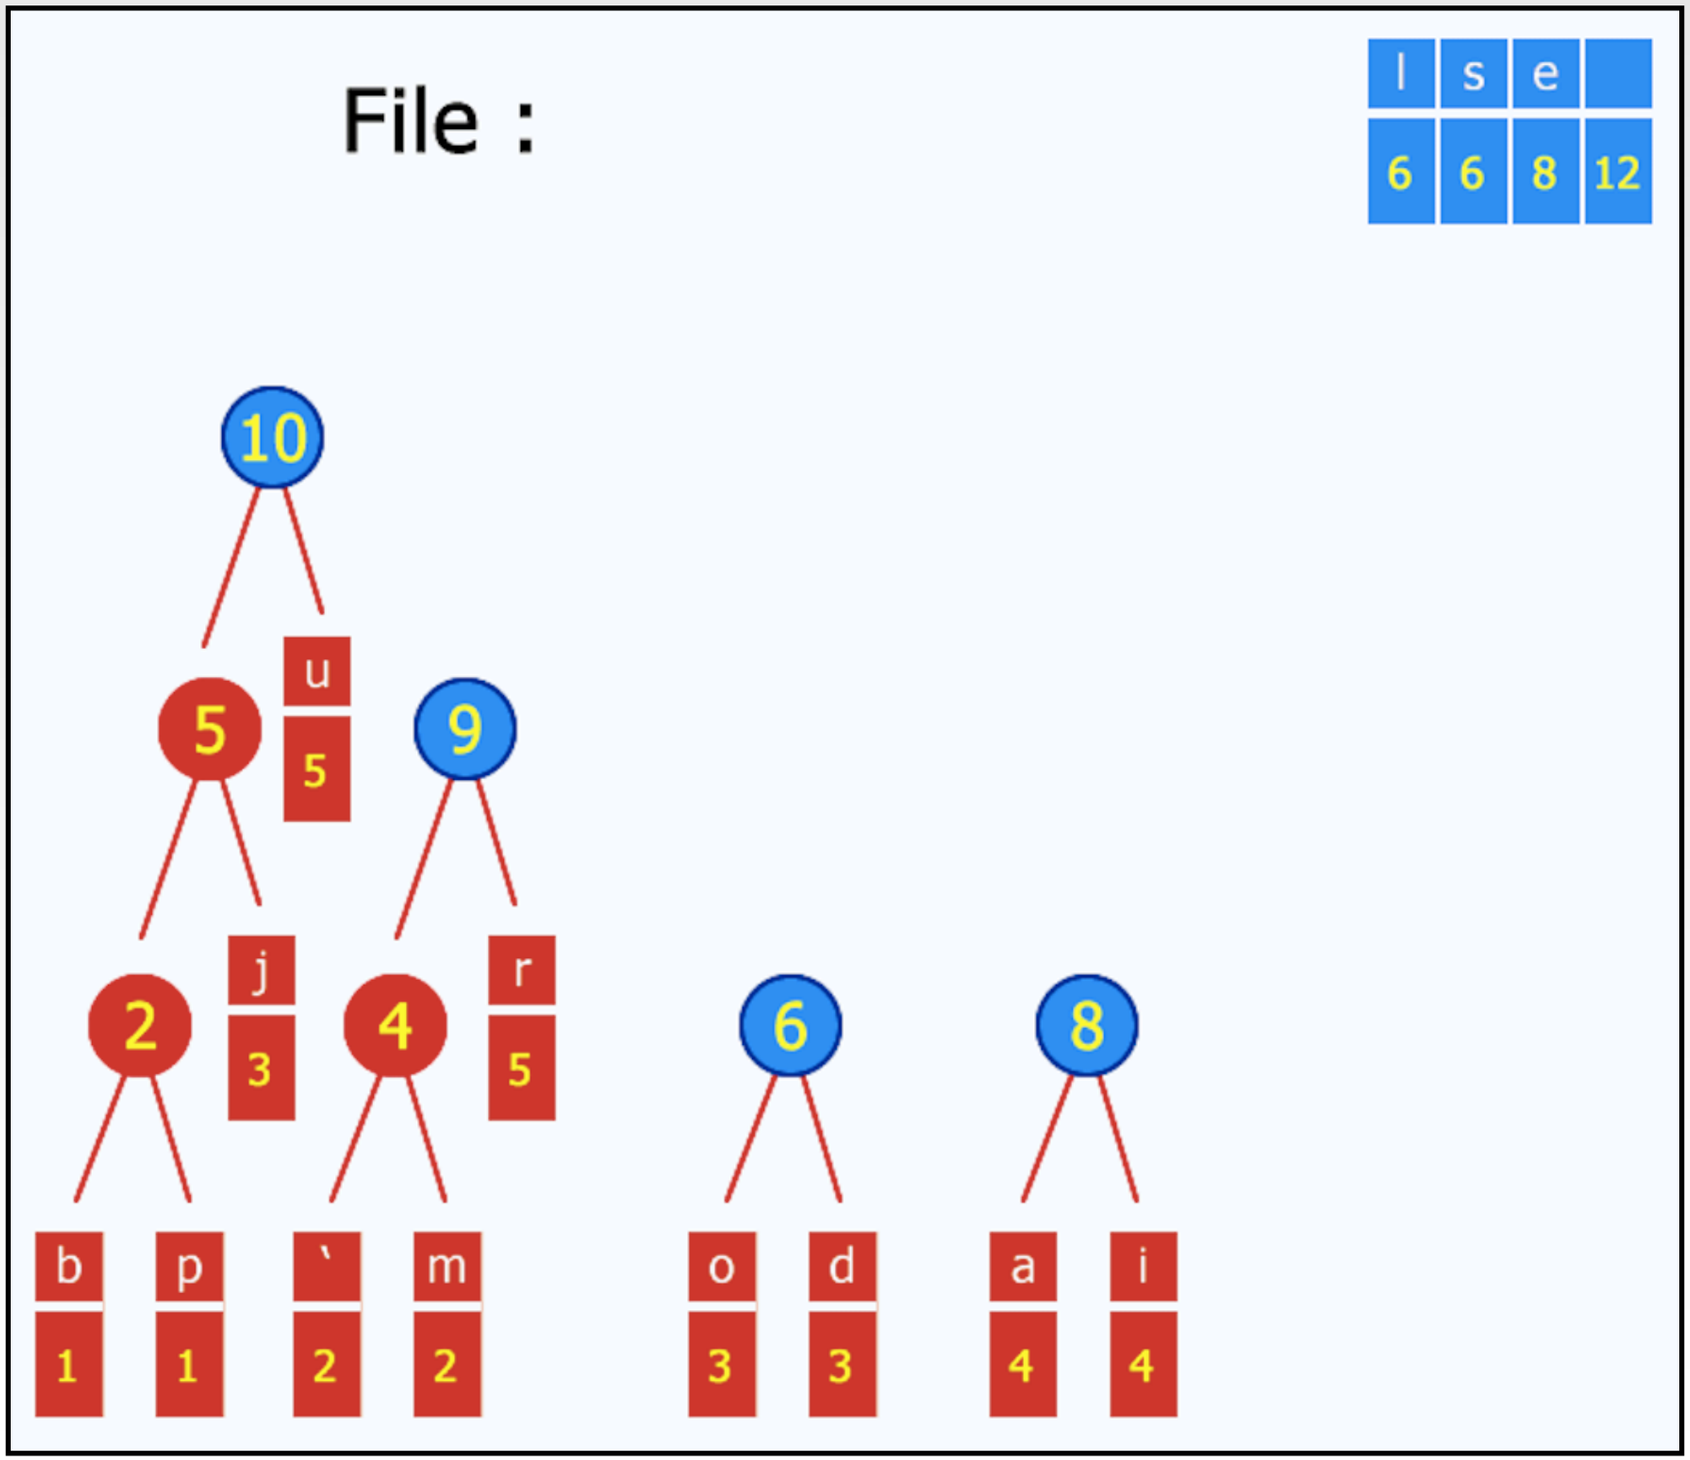

Árvore de Huffman

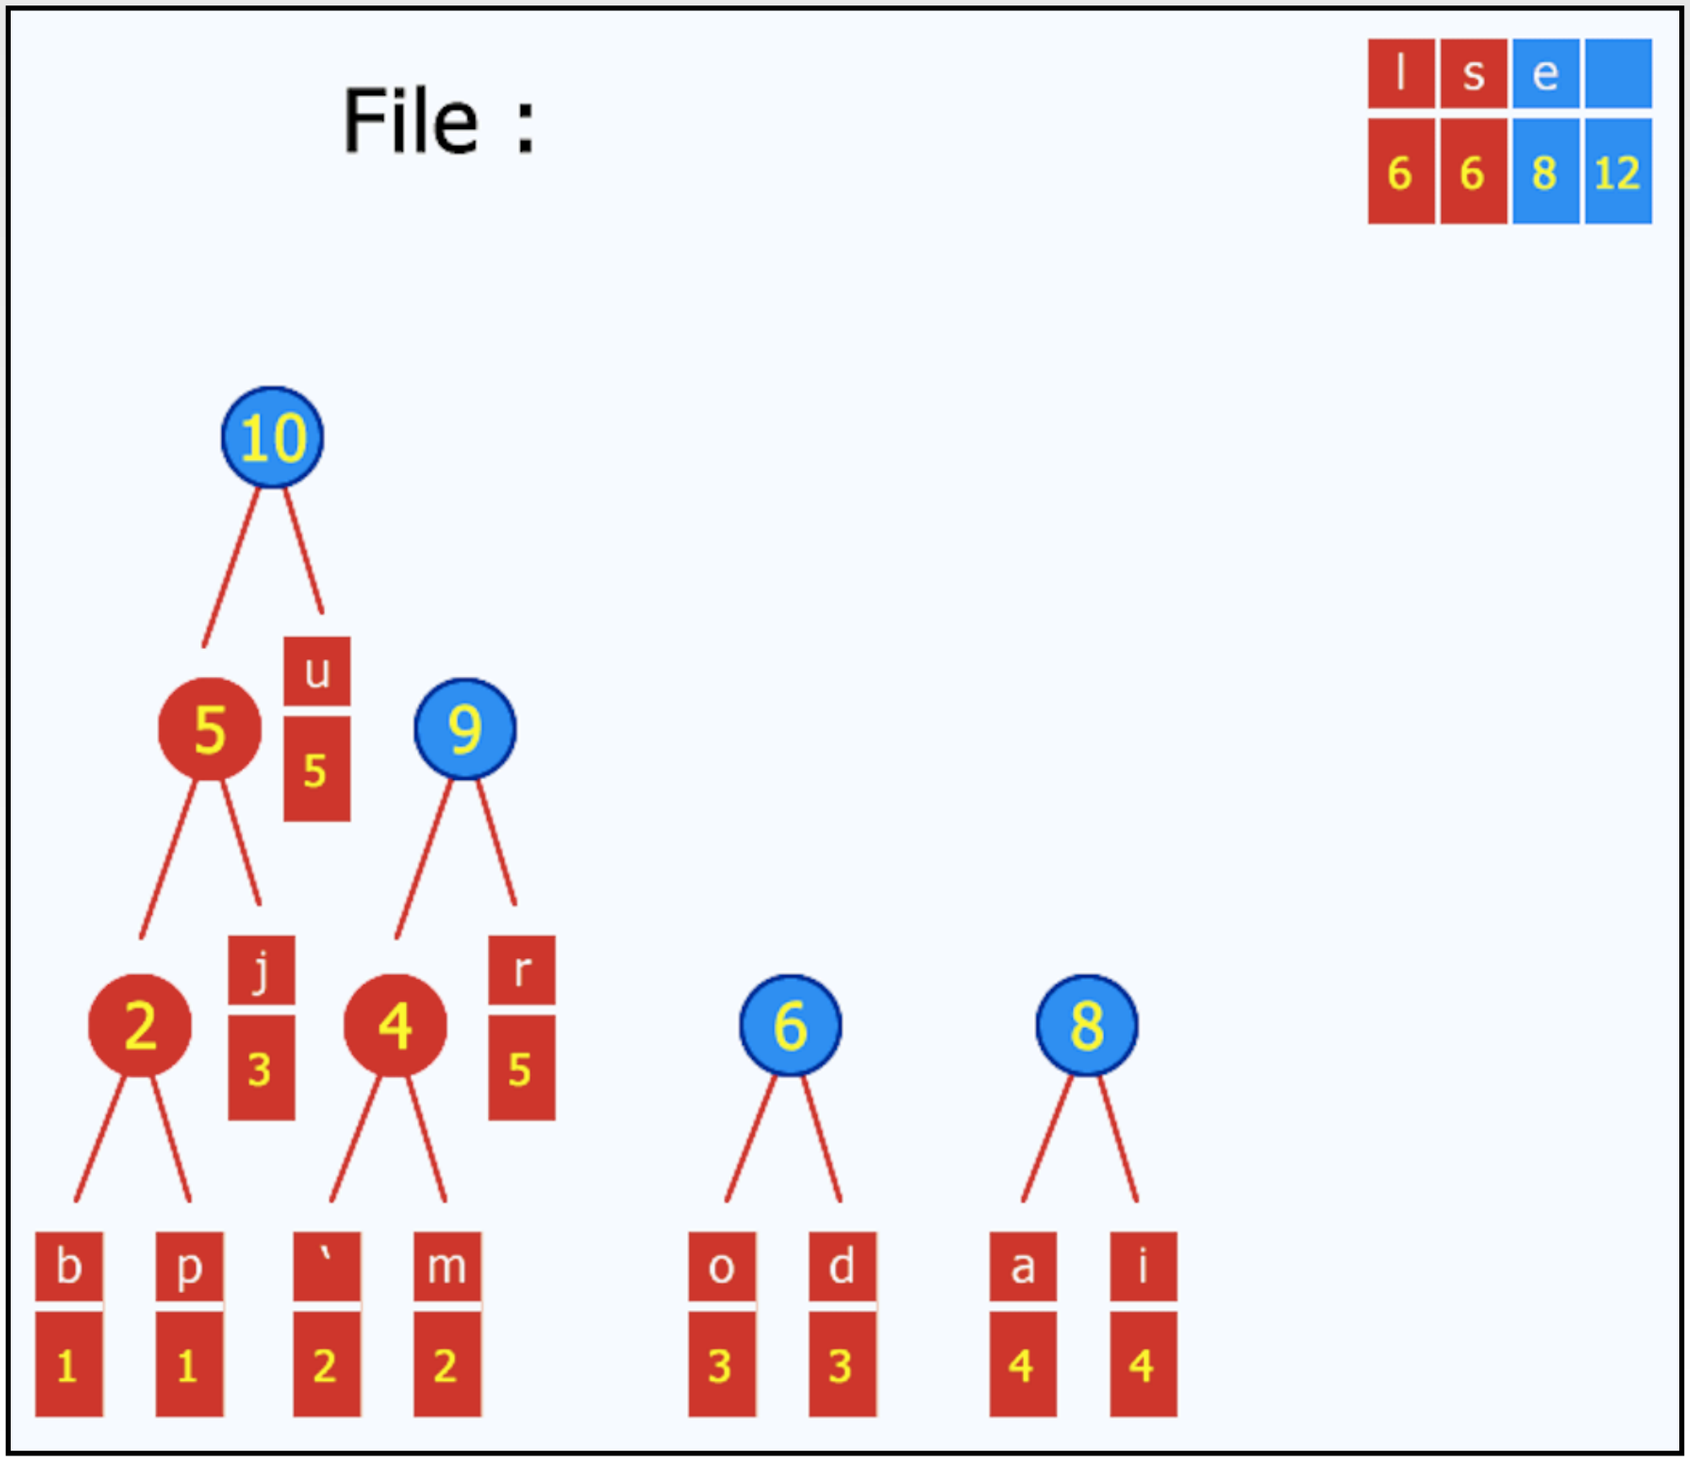

Árvore de Huffman

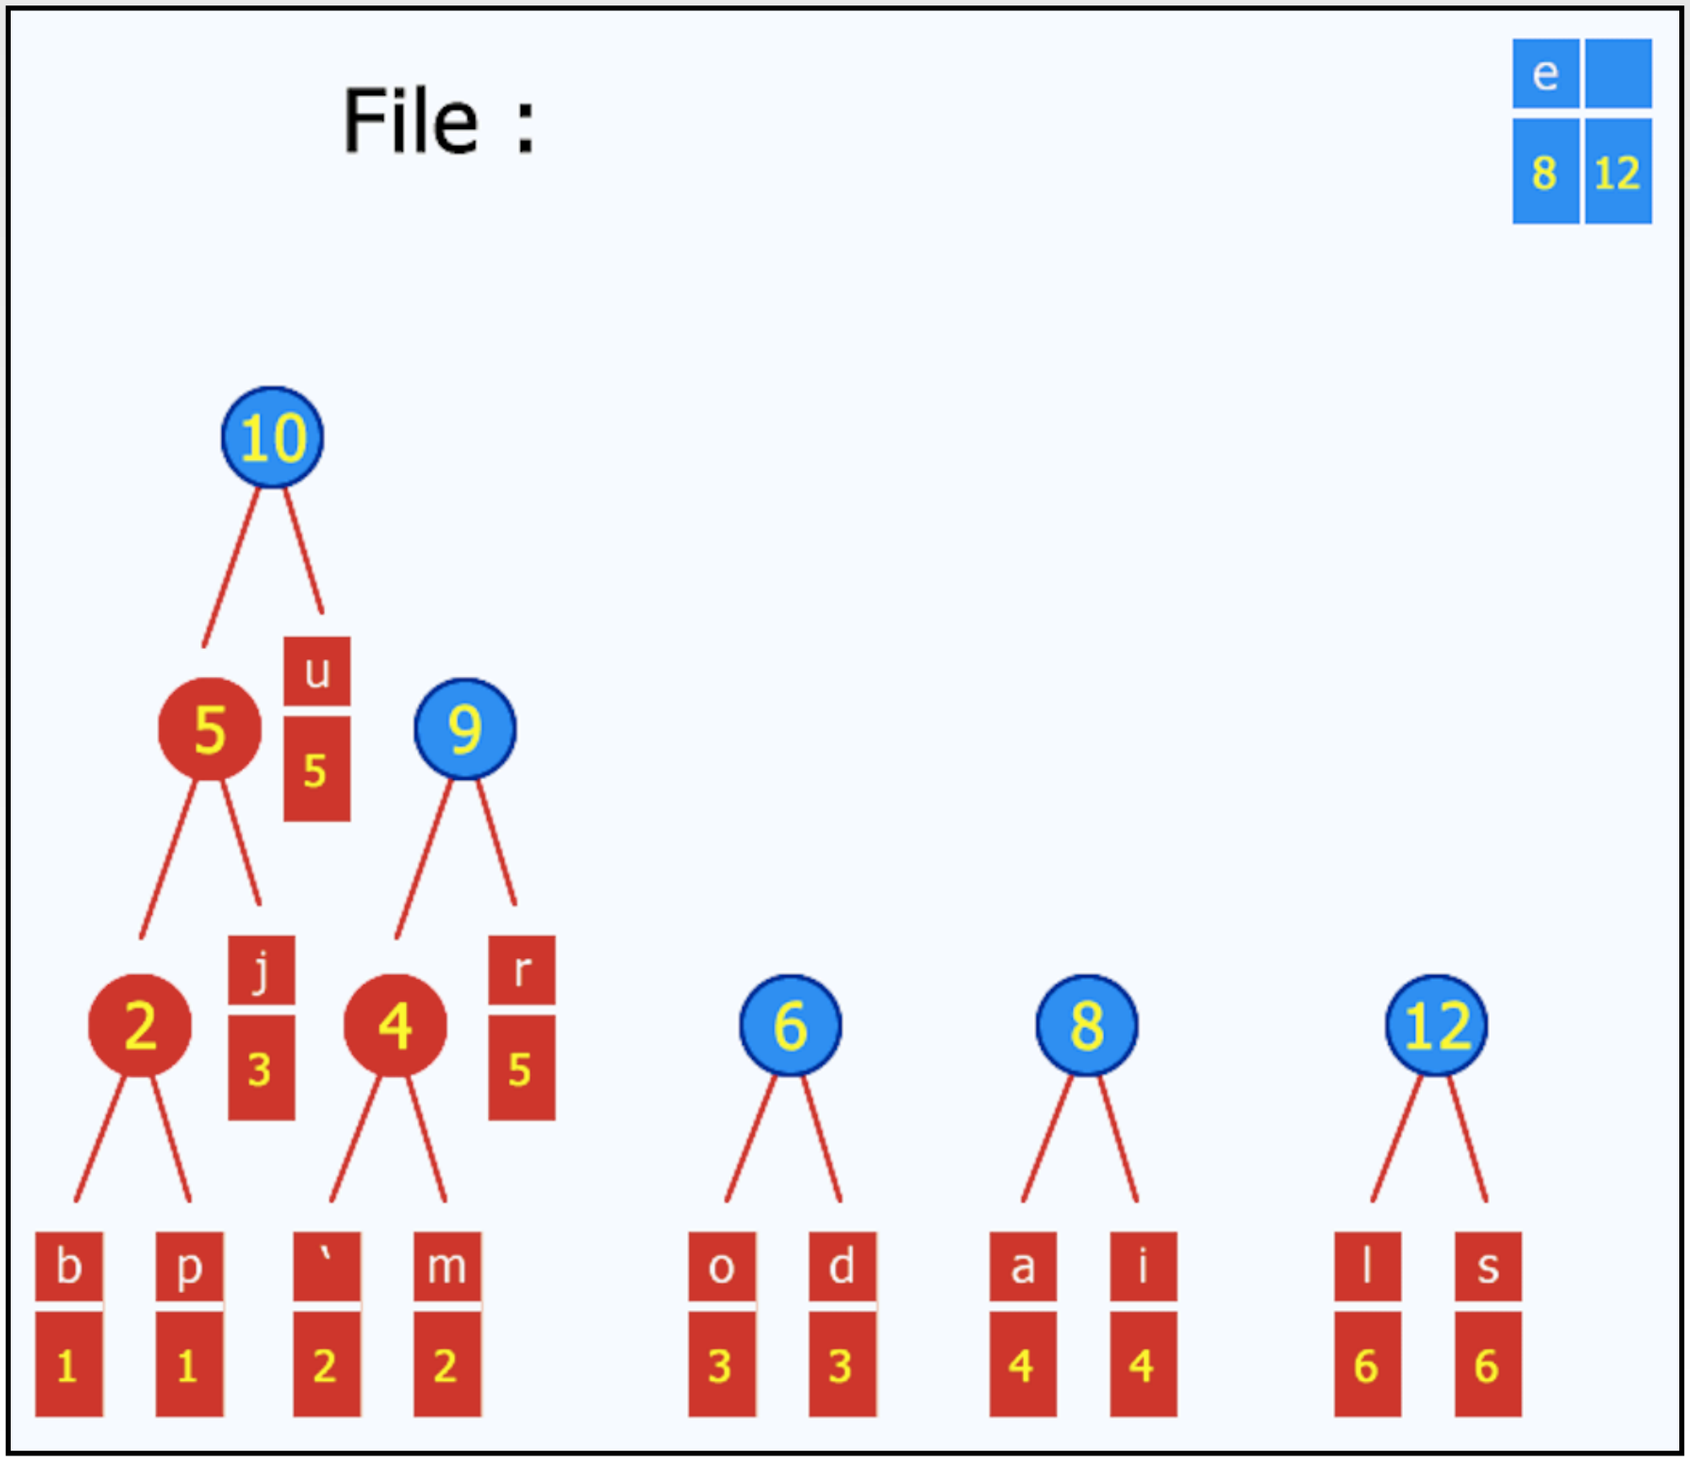

Árvore de Huffman

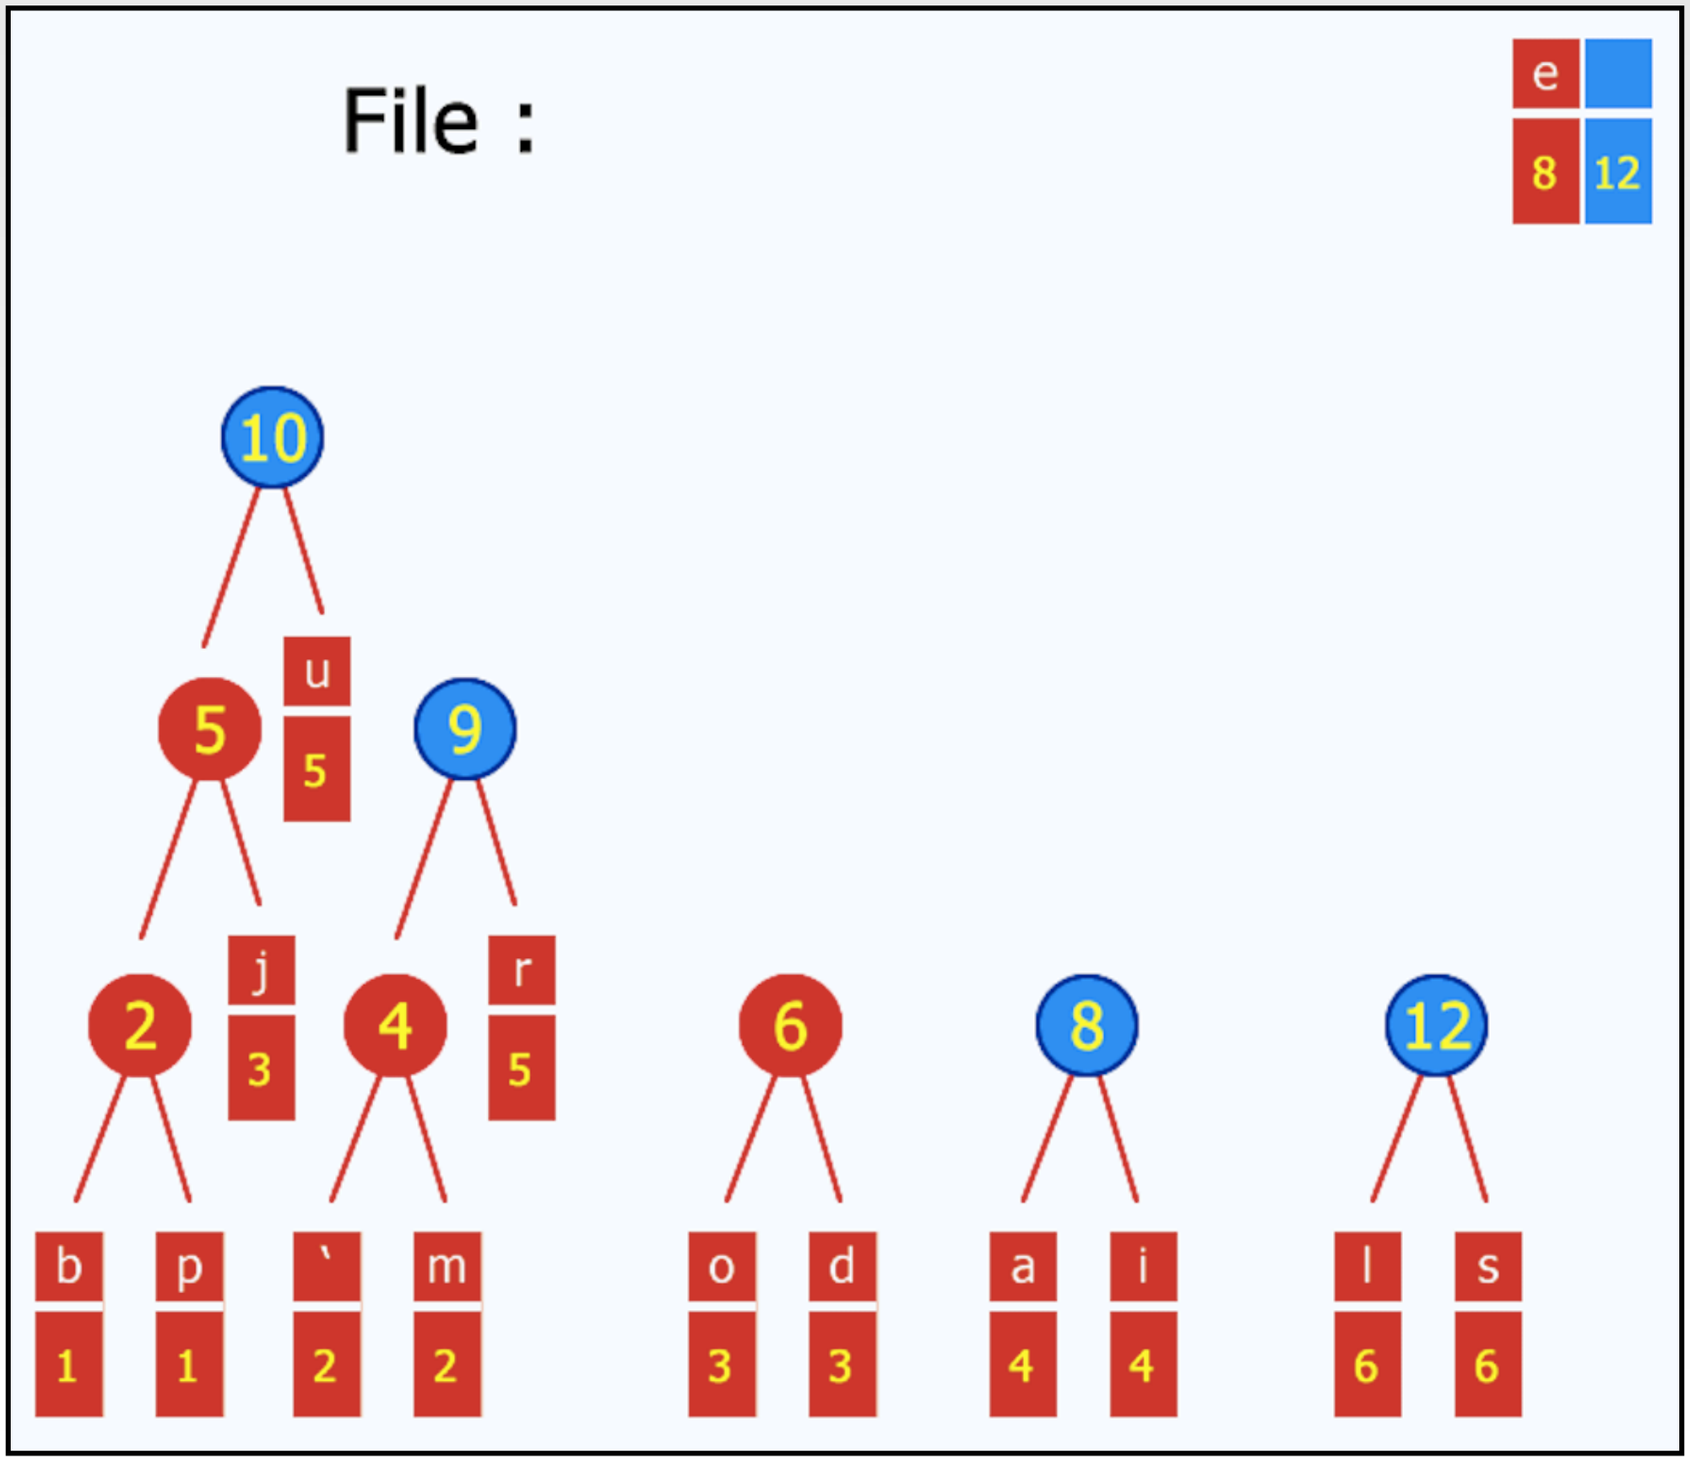

Árvore de Huffman

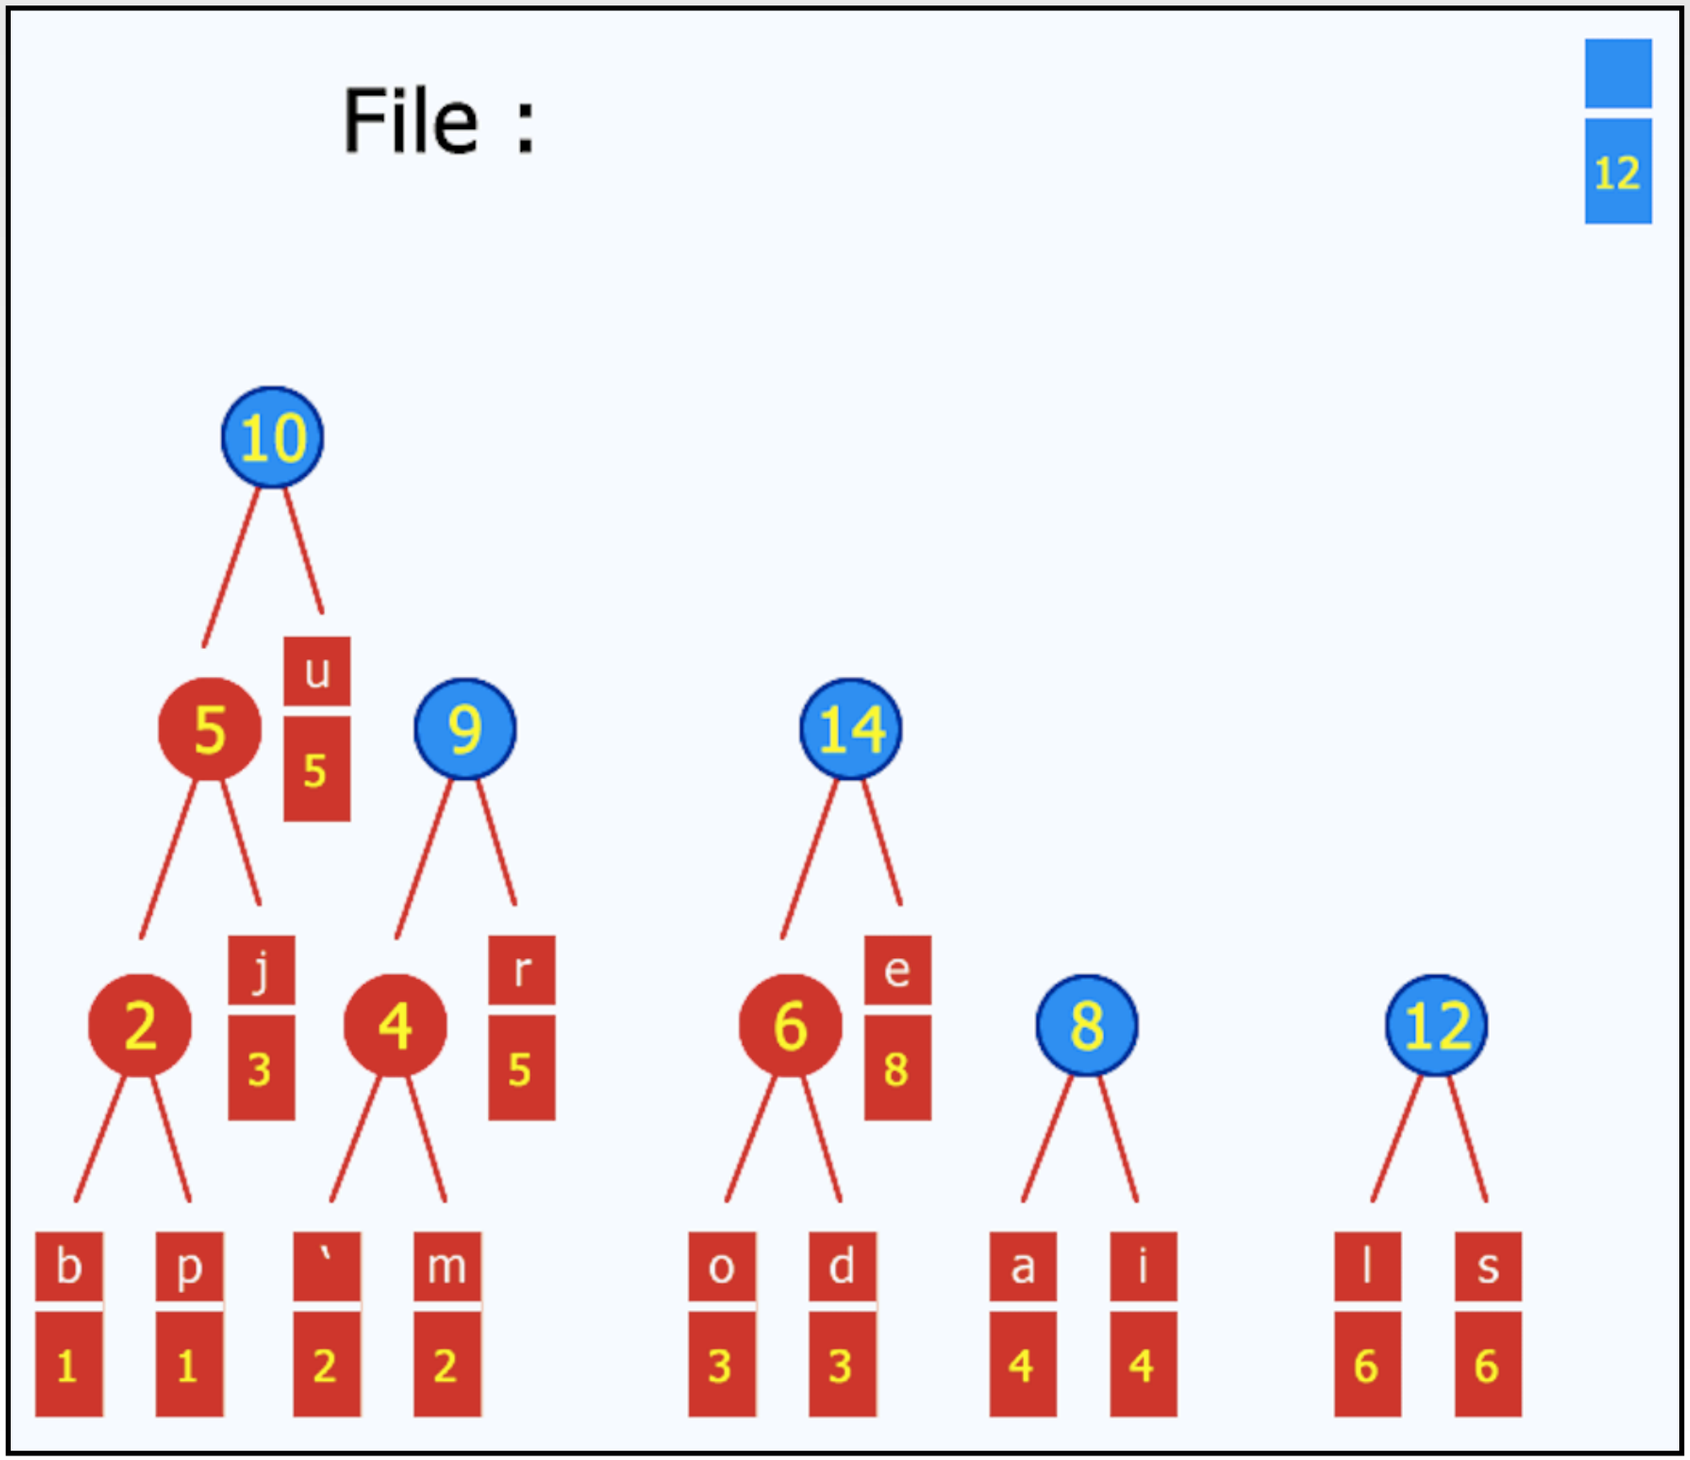

Árvore de Huffman

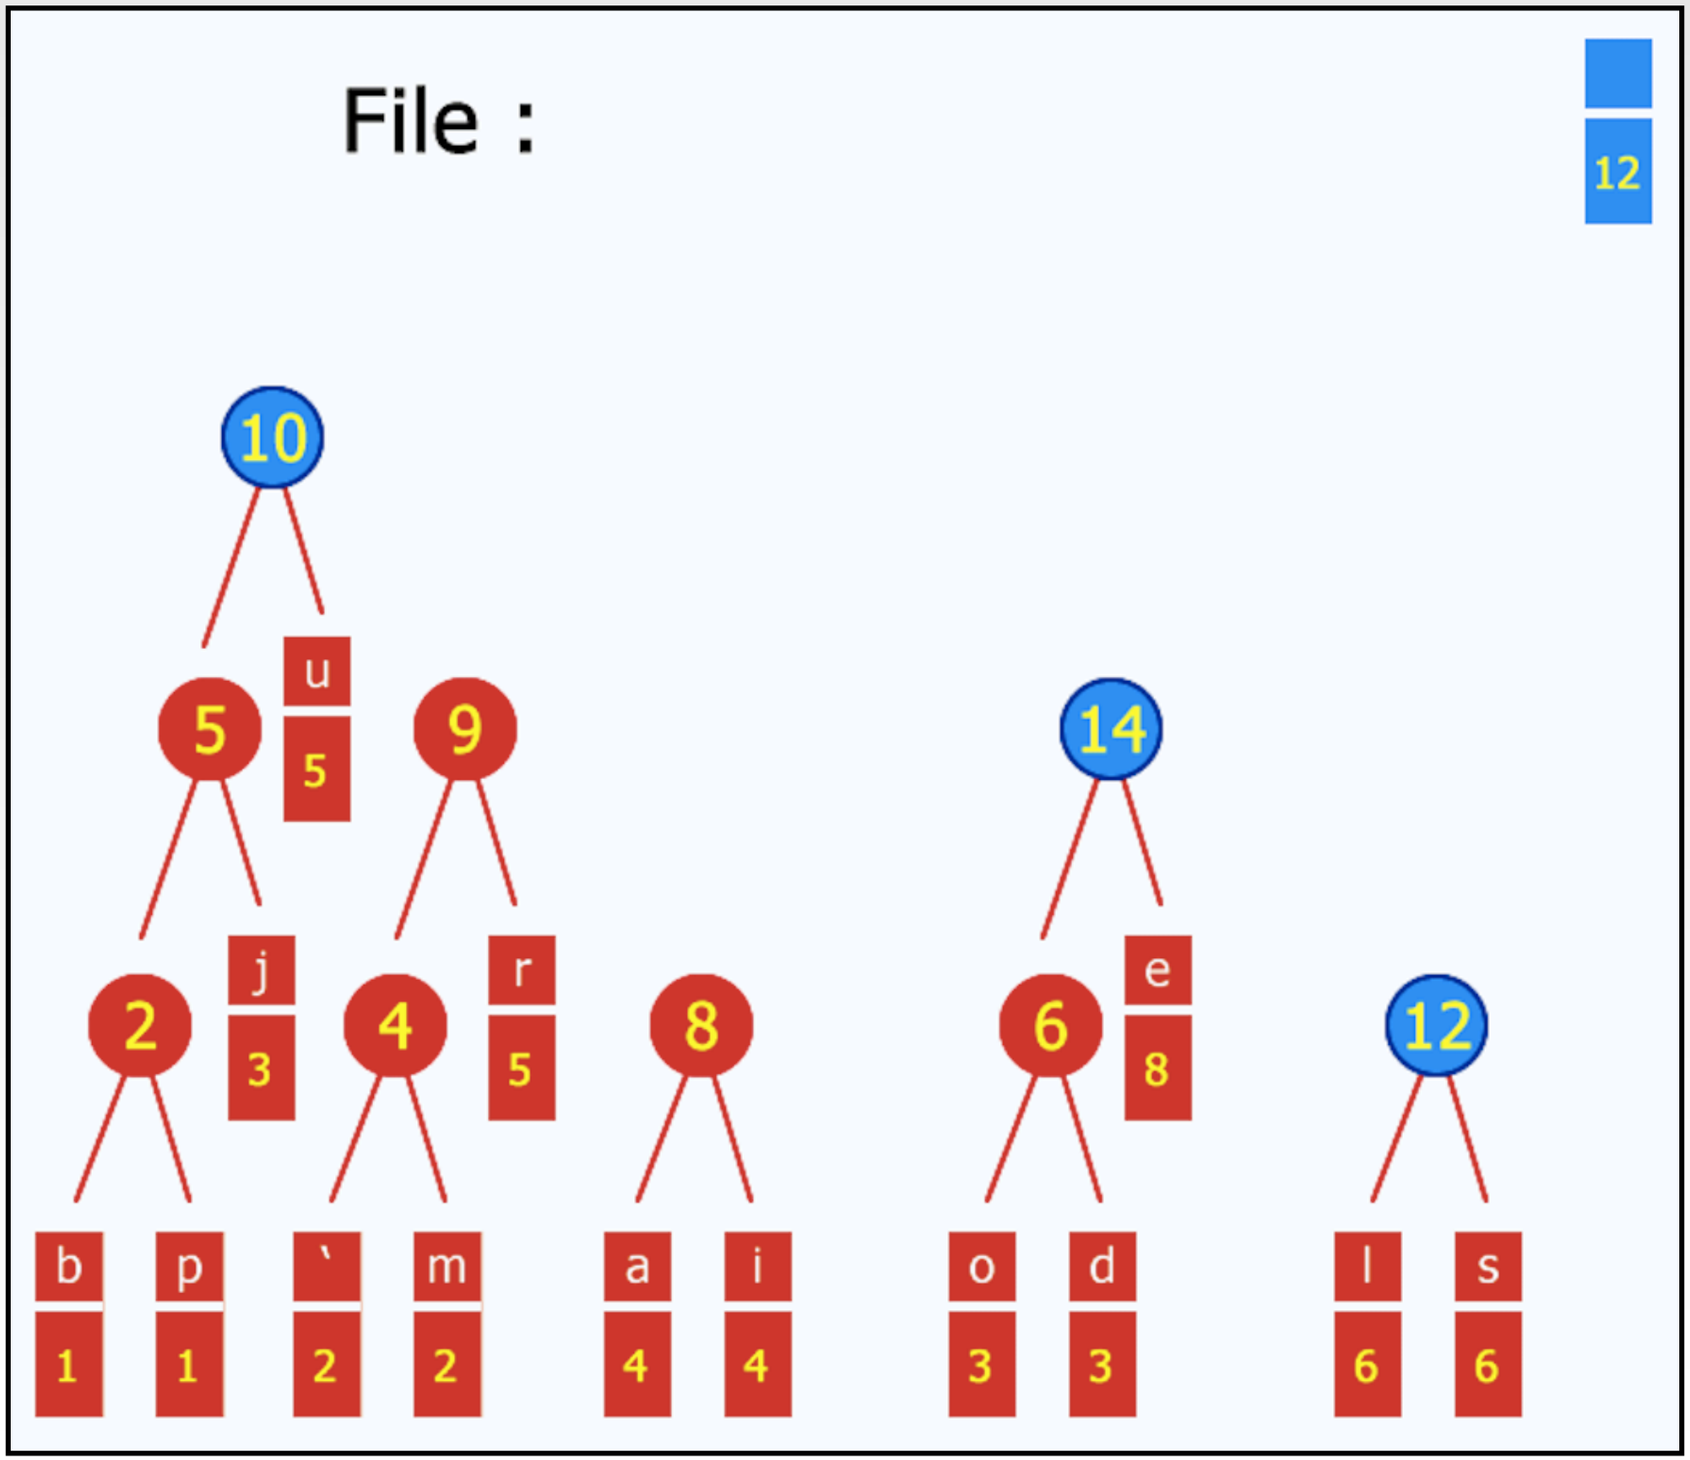

Árvore de Huffman

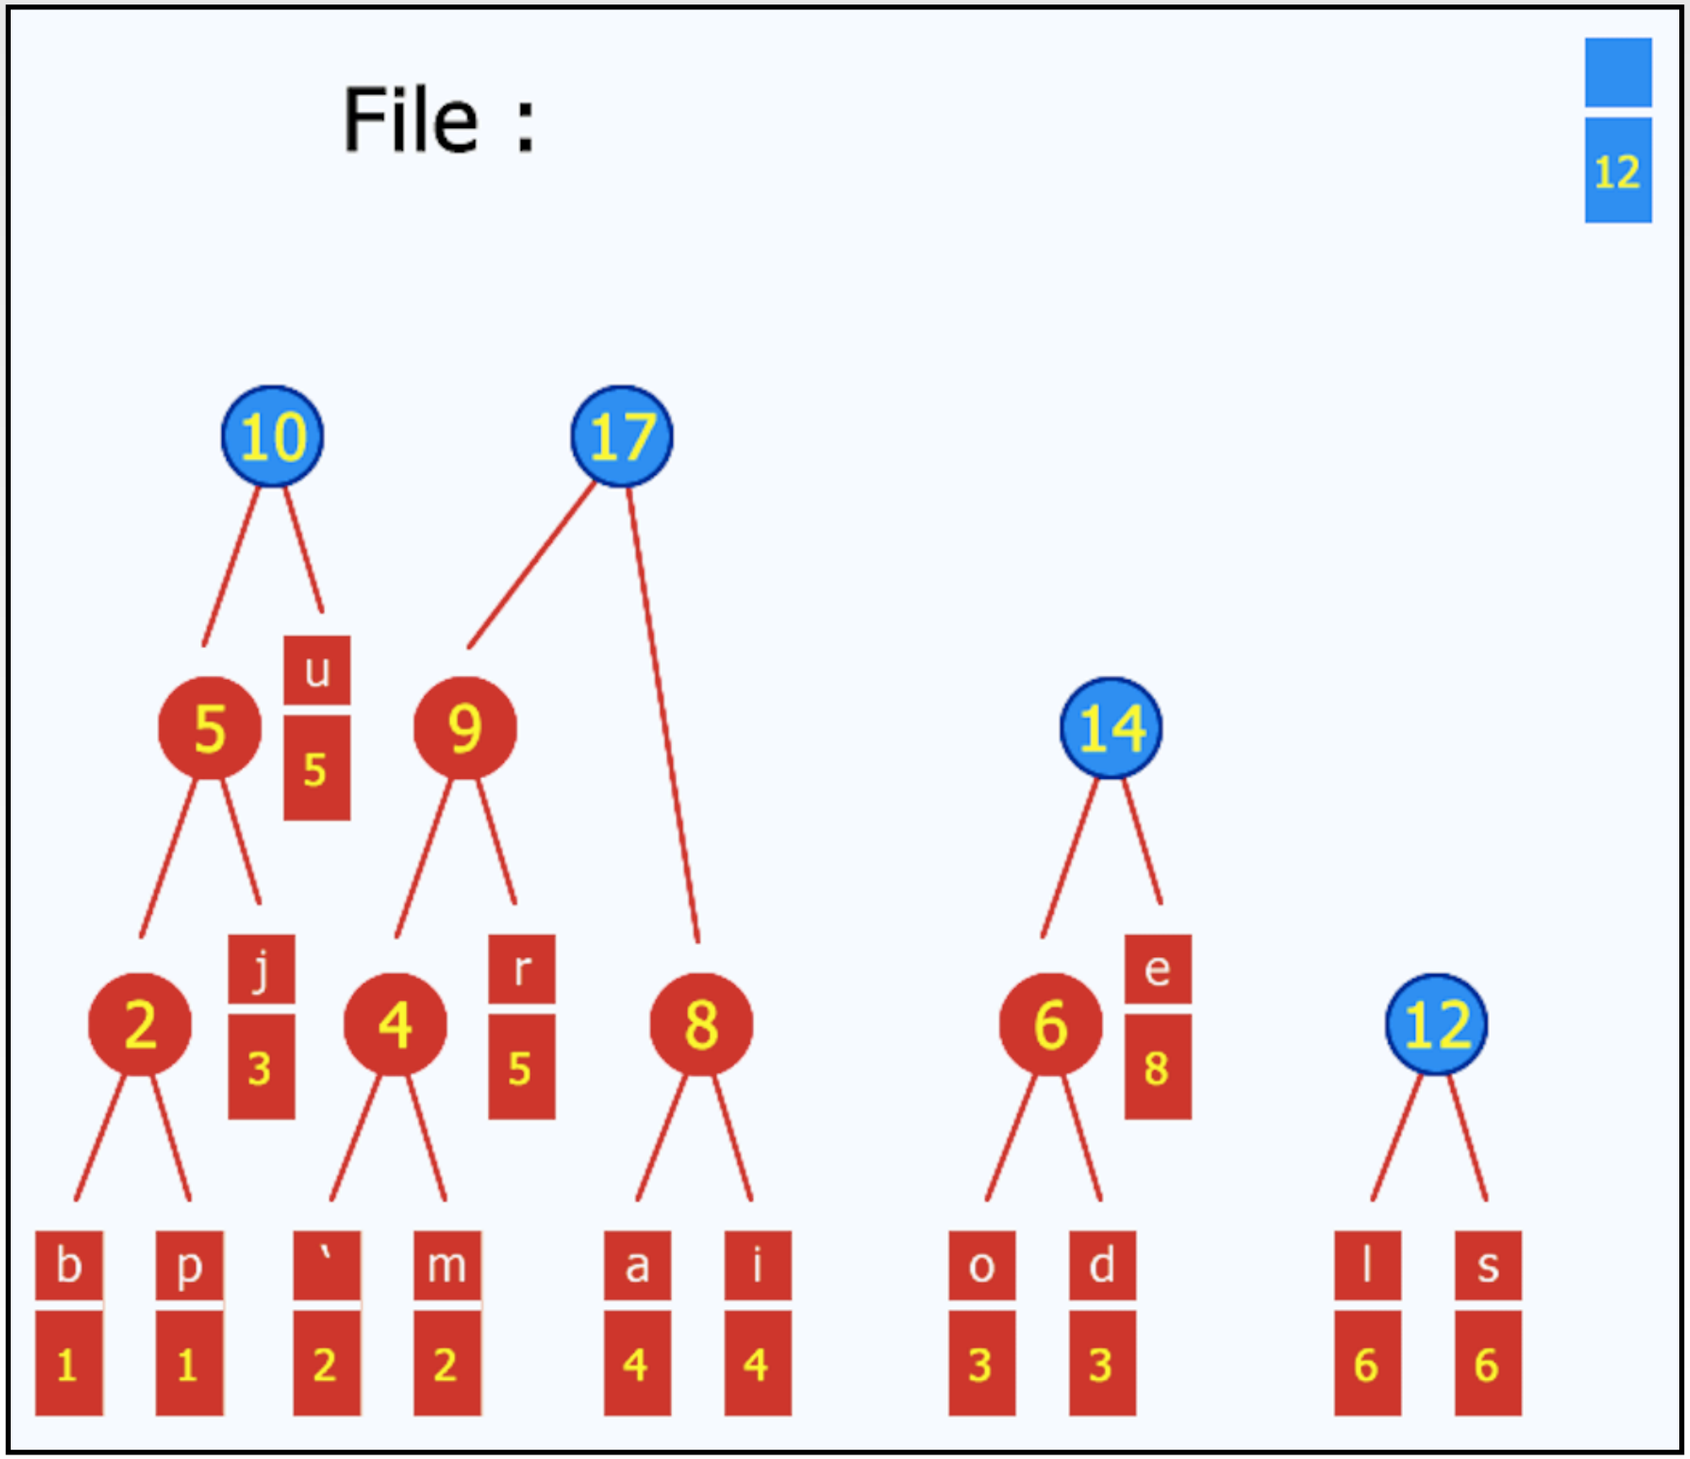

Árvore de Huffman

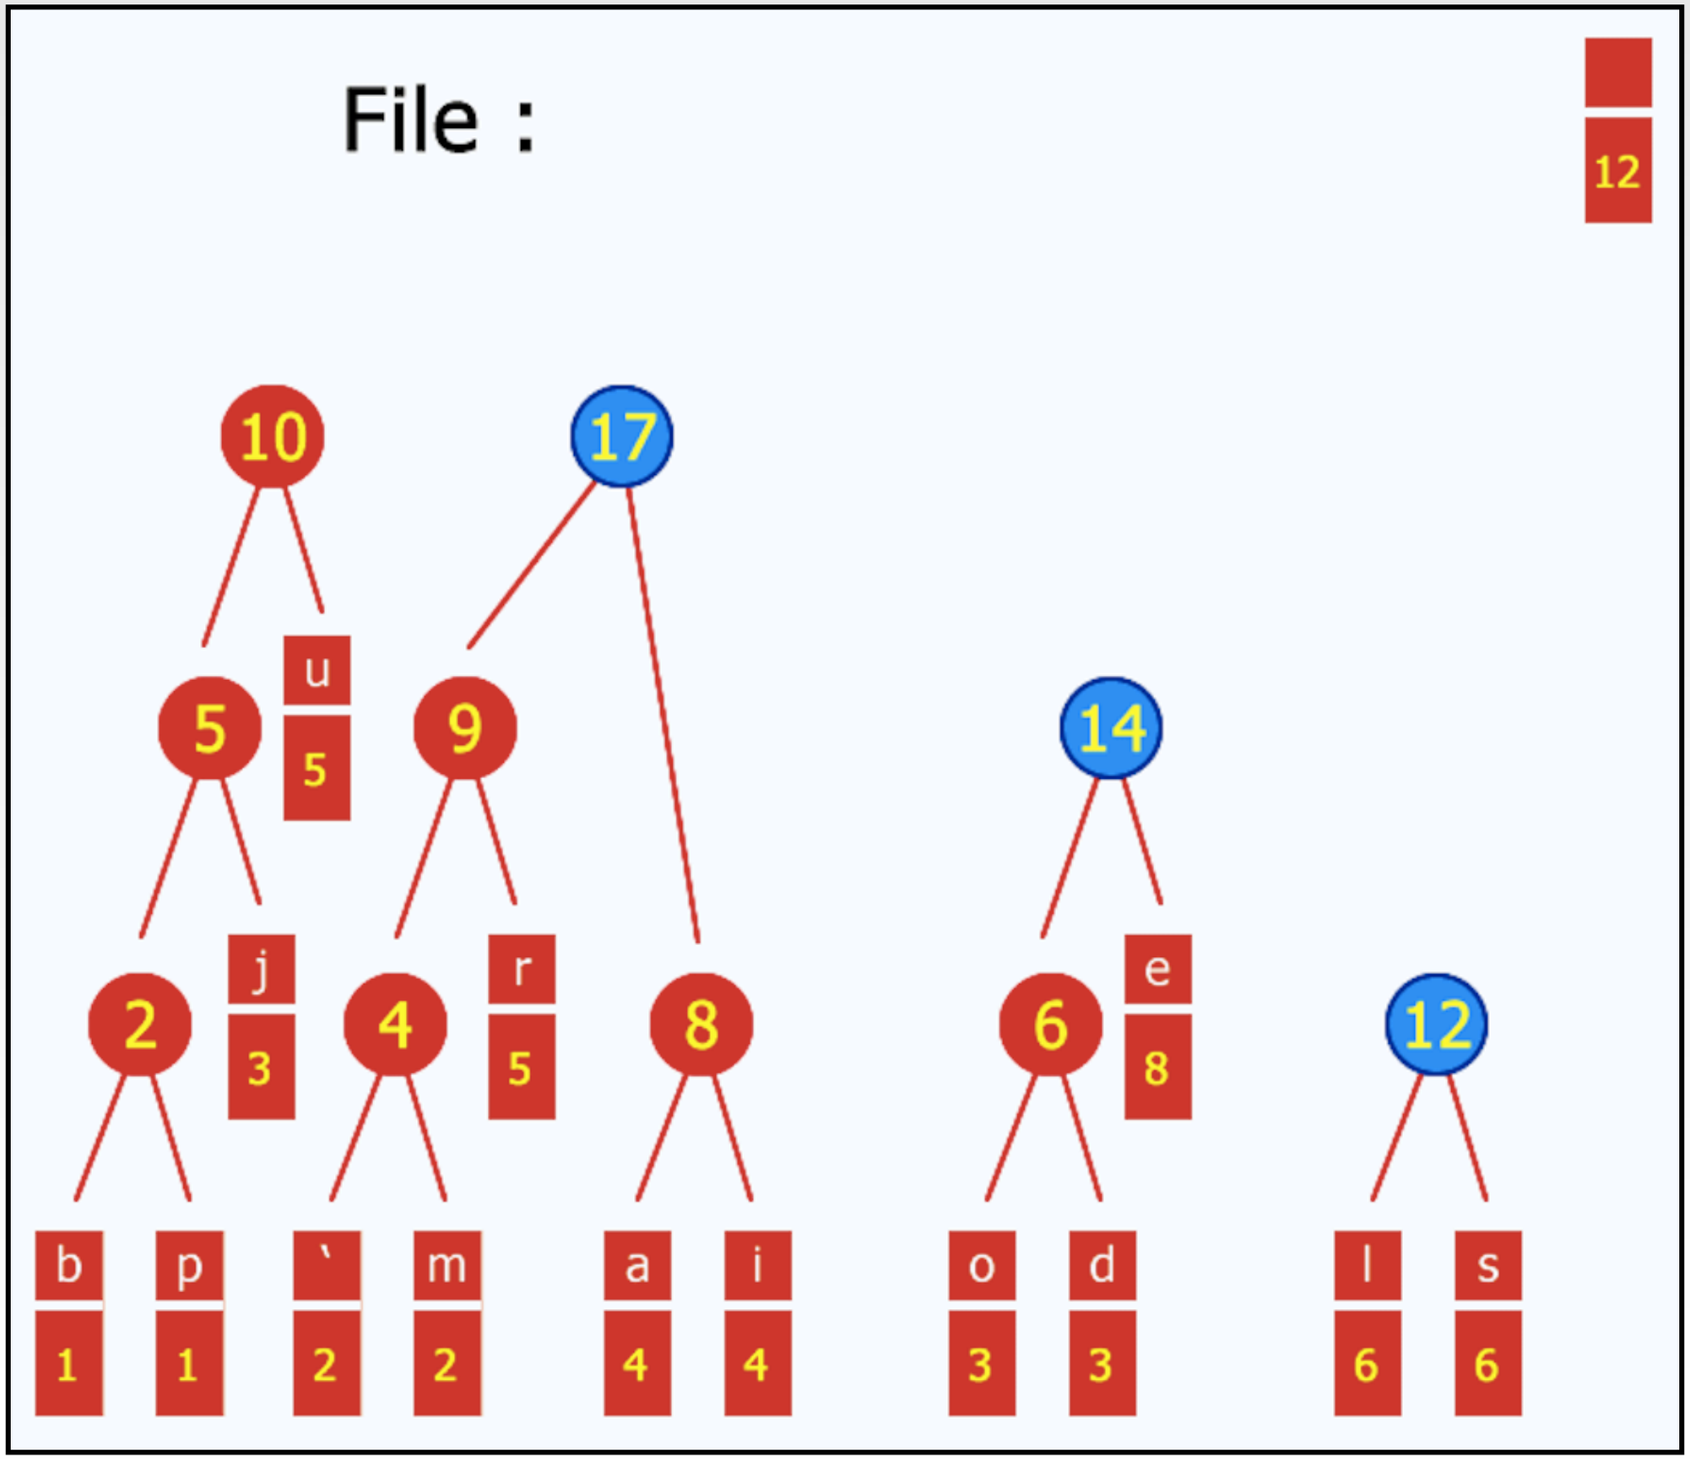

Árvore de Huffman

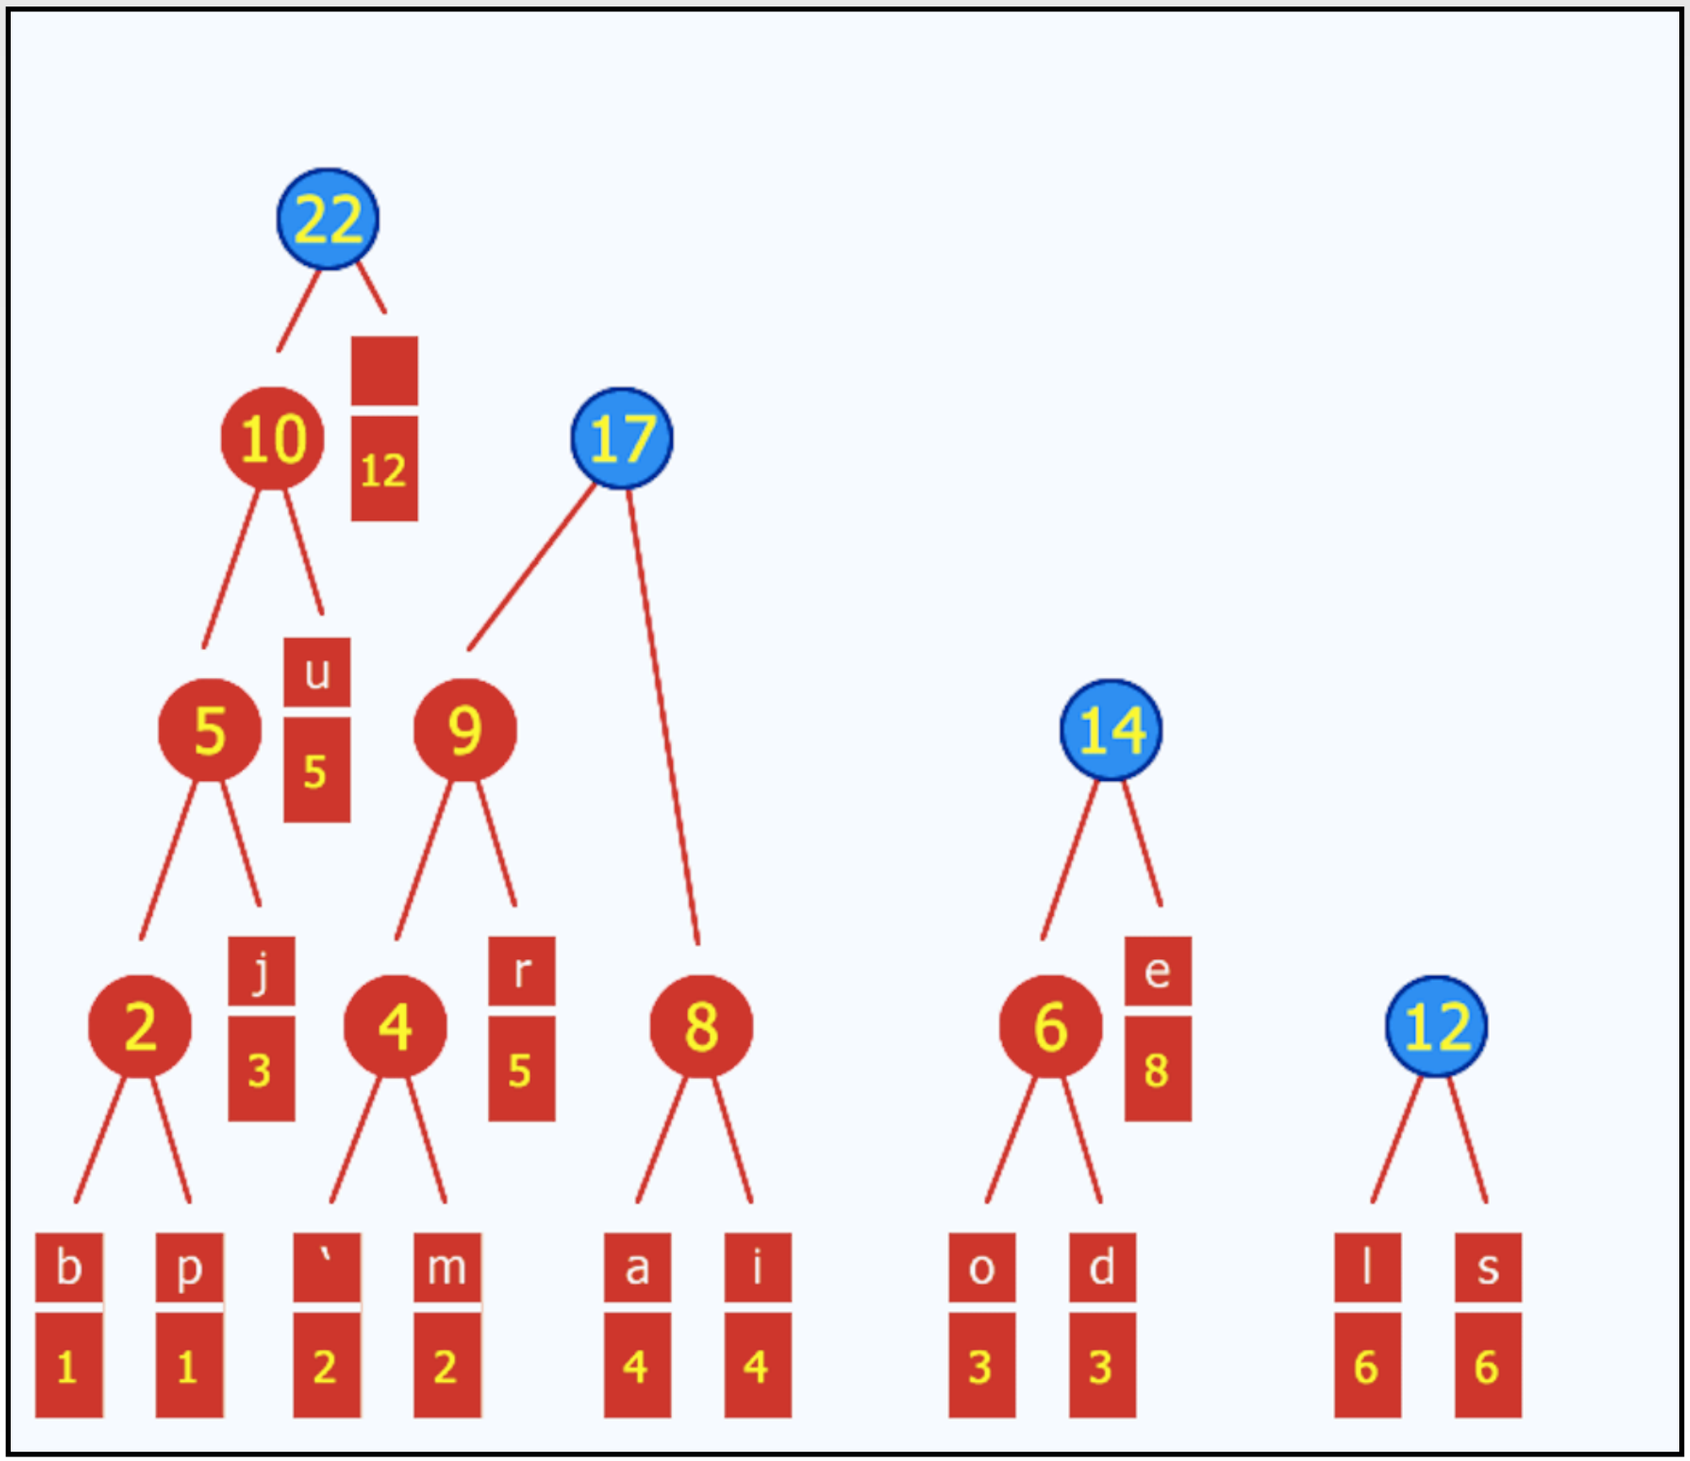

Árvore de Huffman

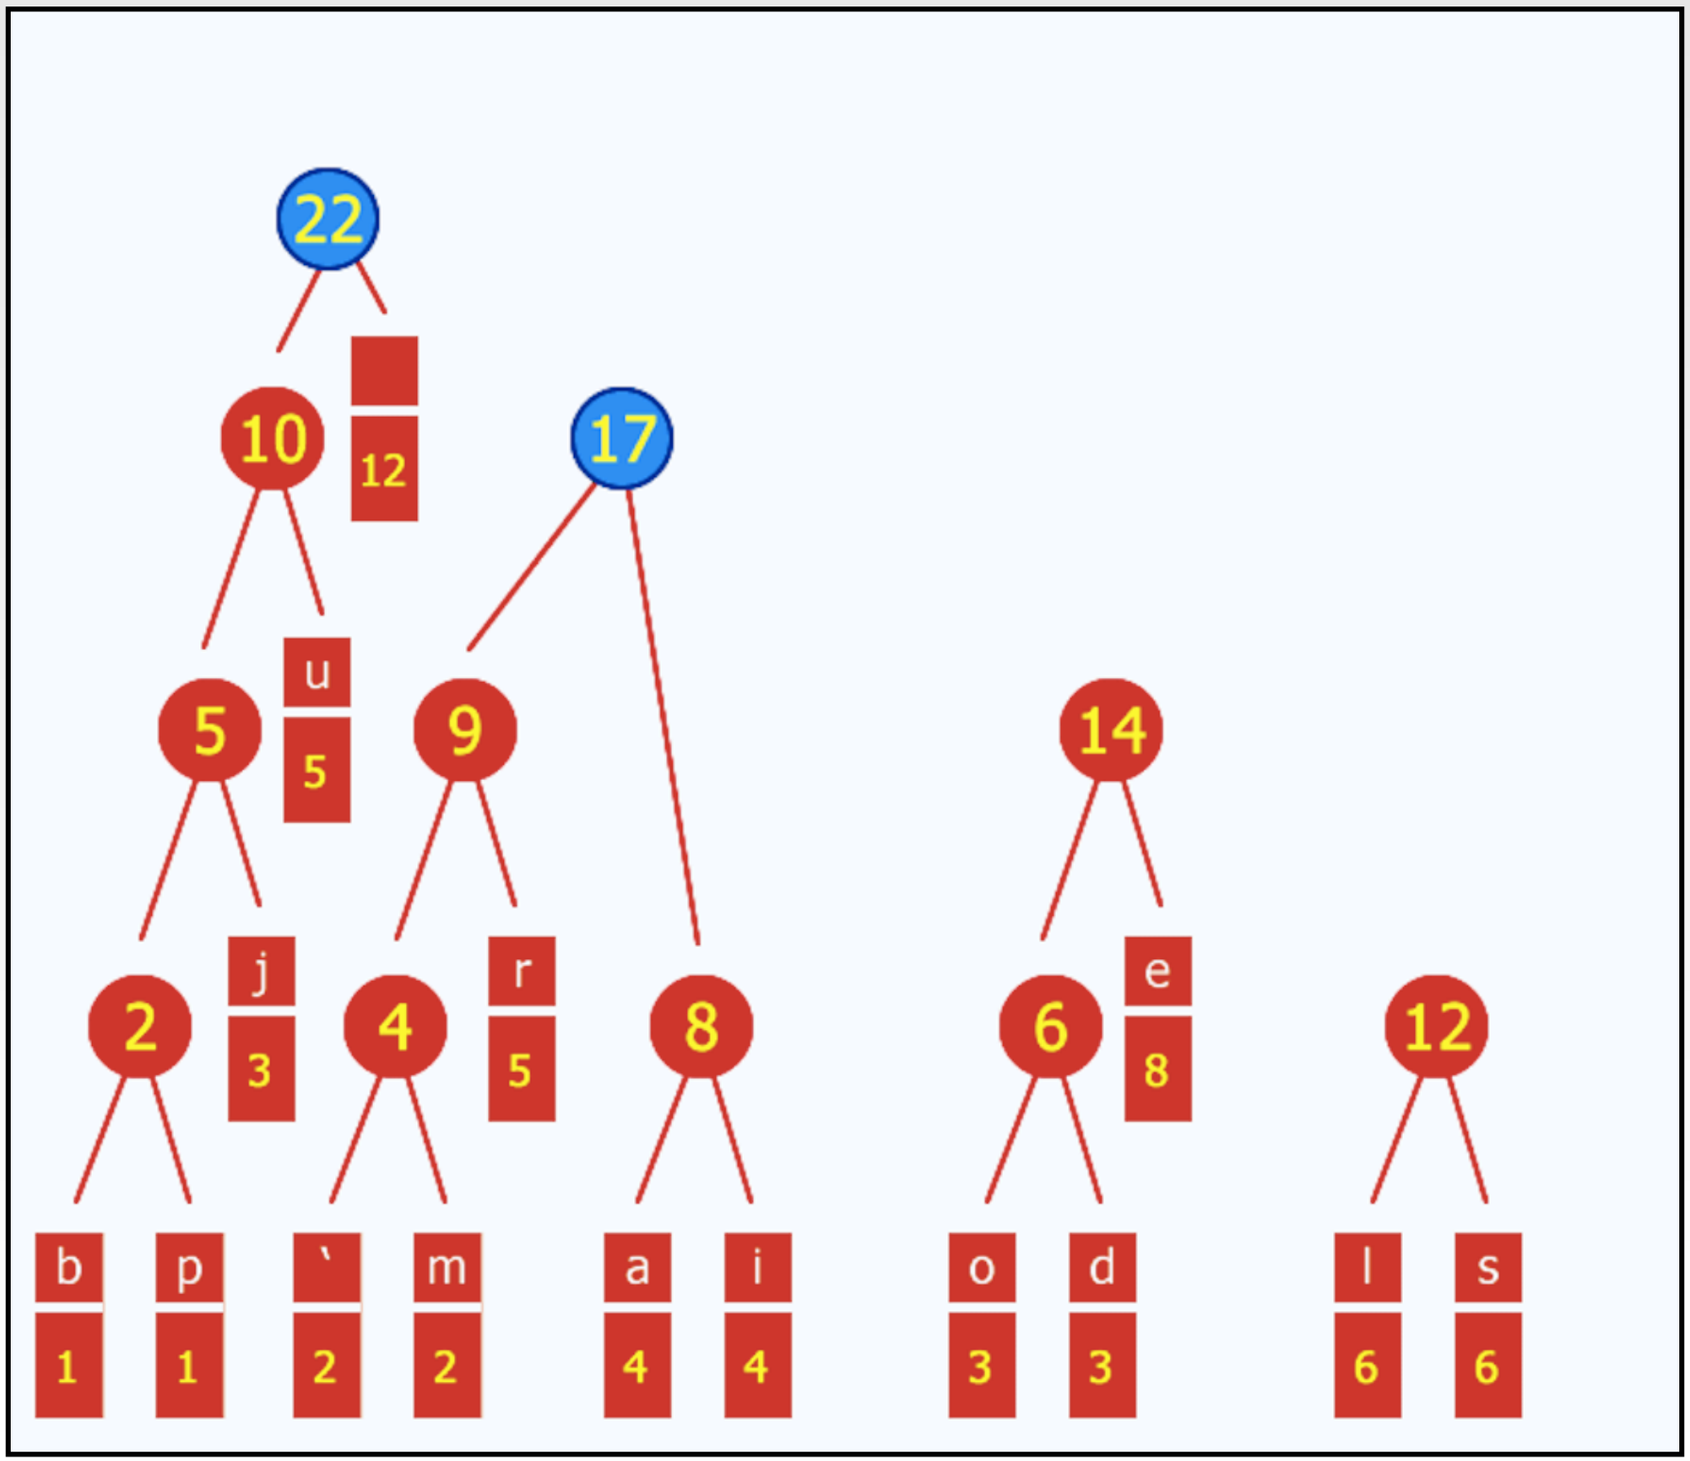

Árvore de Huffman

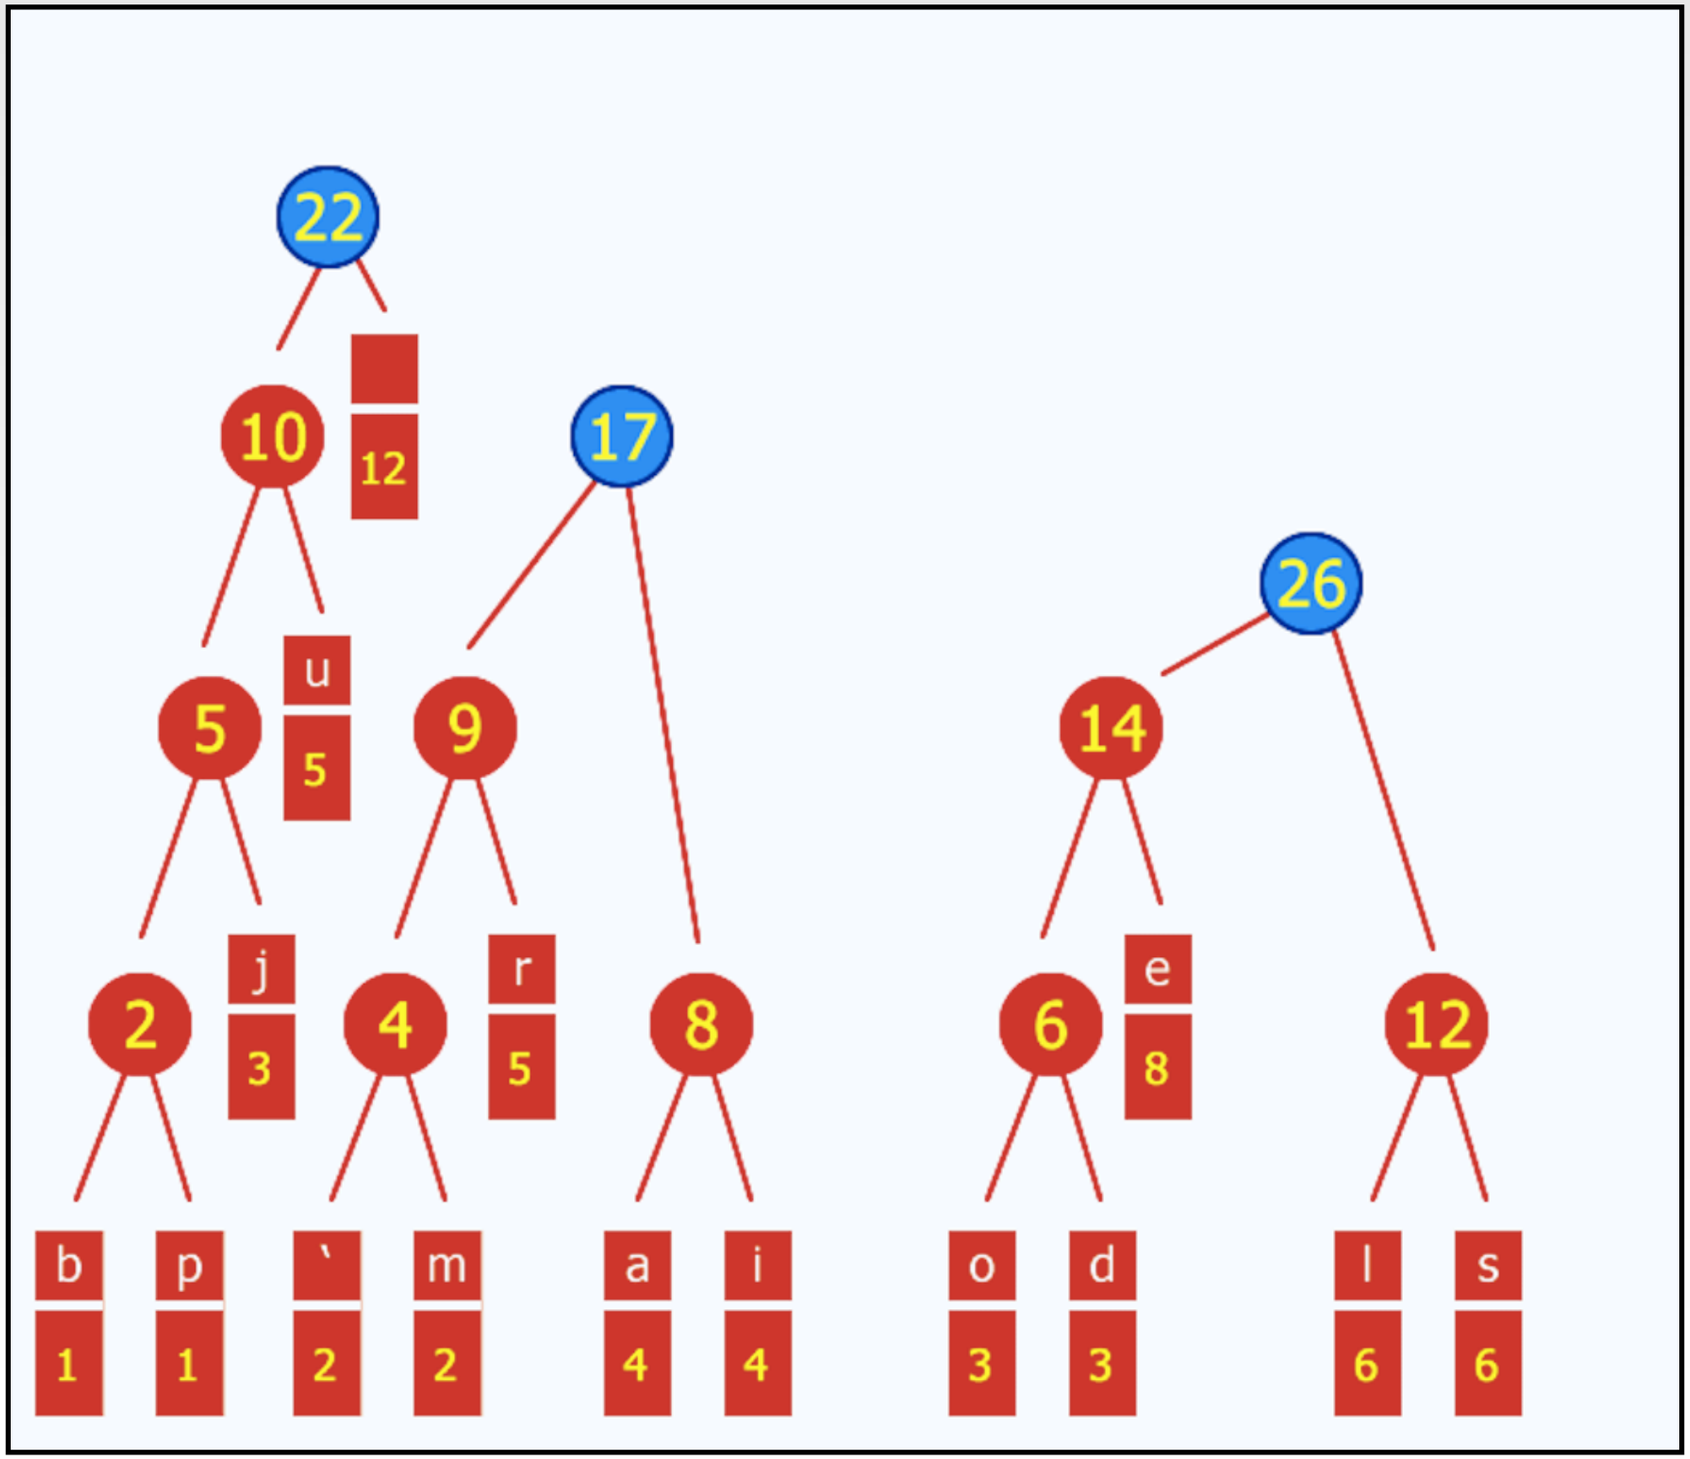

Árvore de Huffman

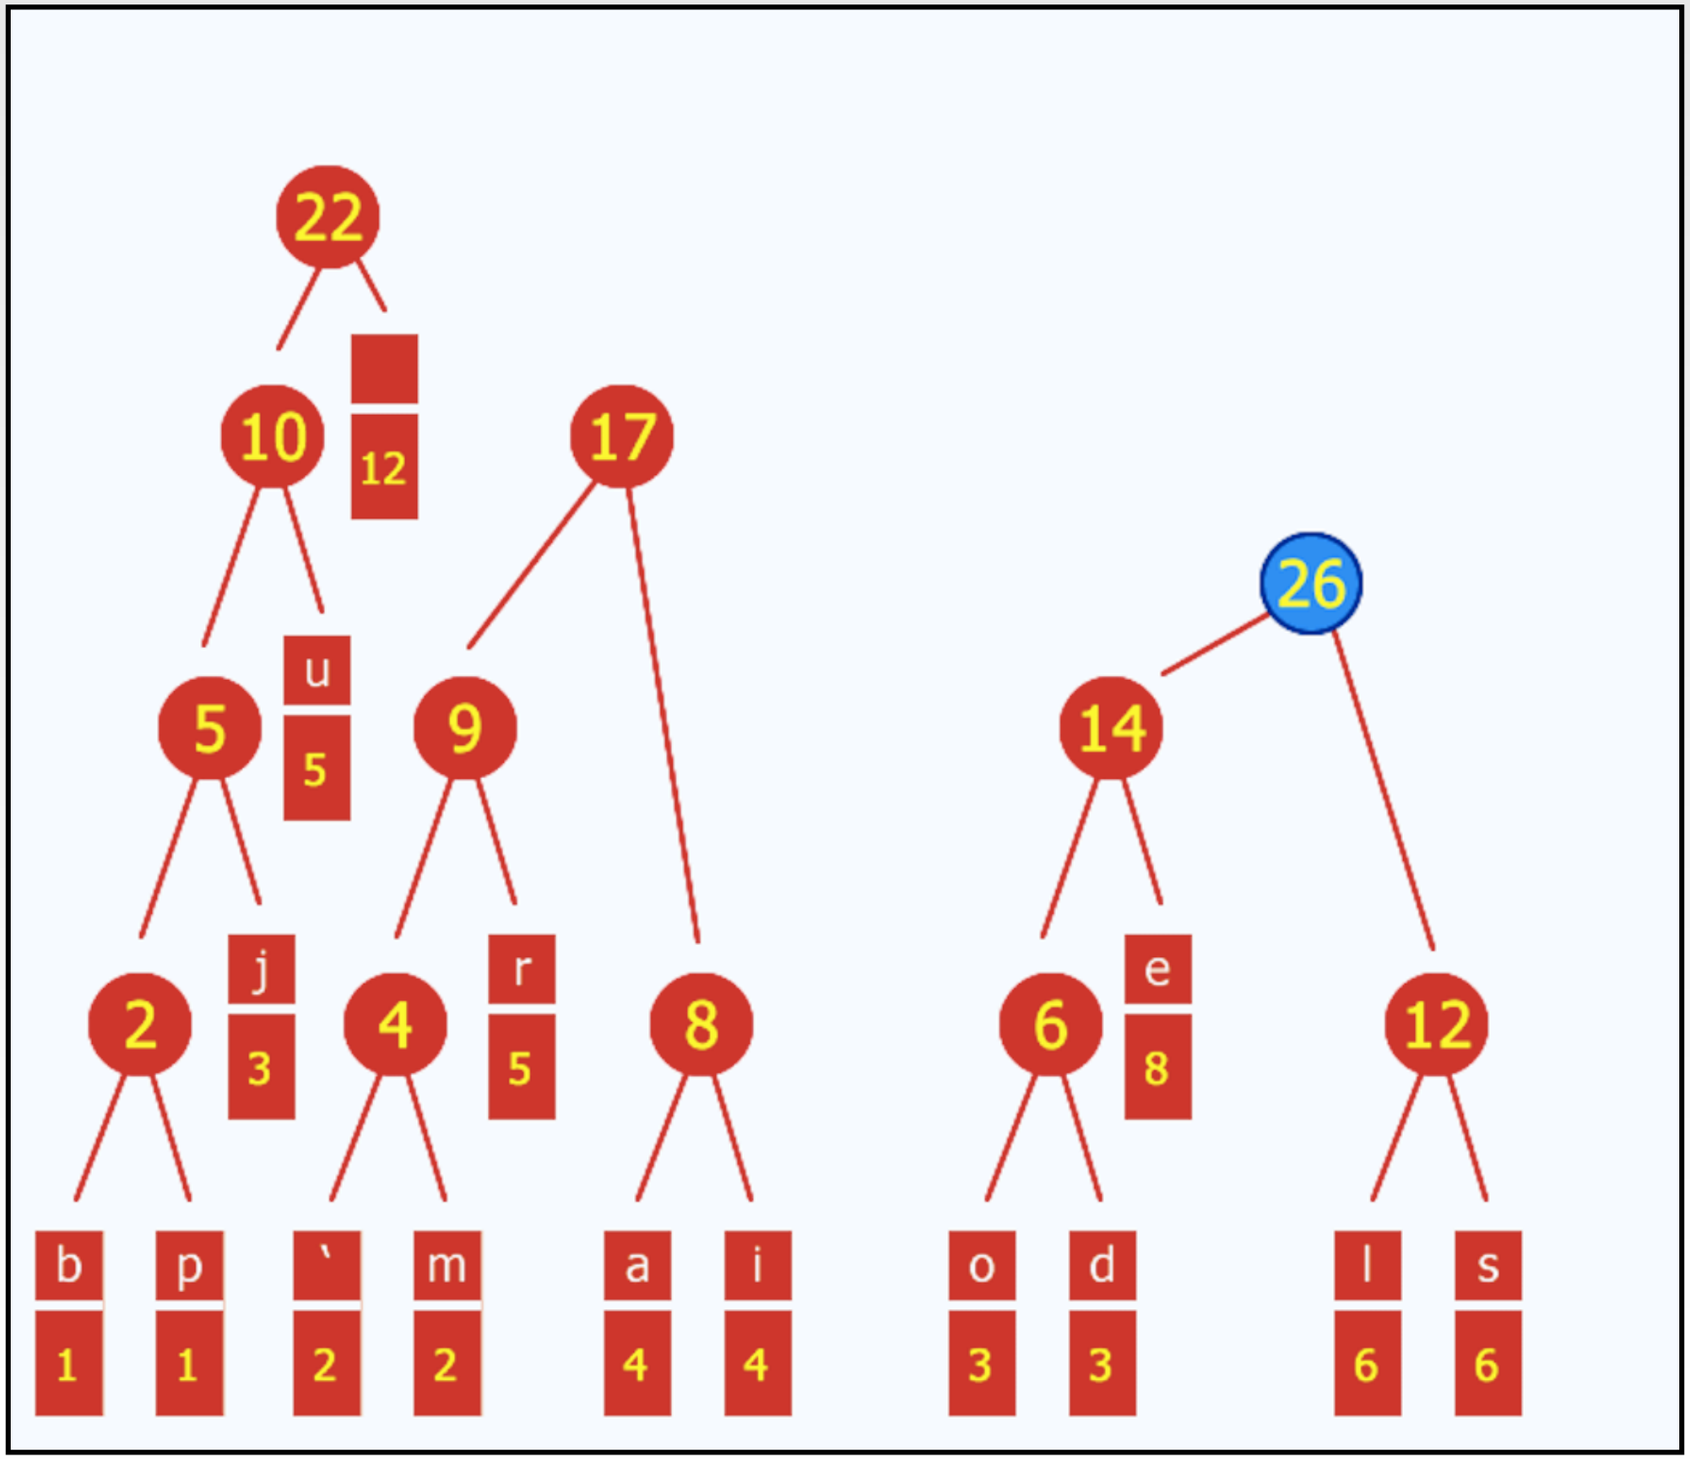

Árvore de Huffman

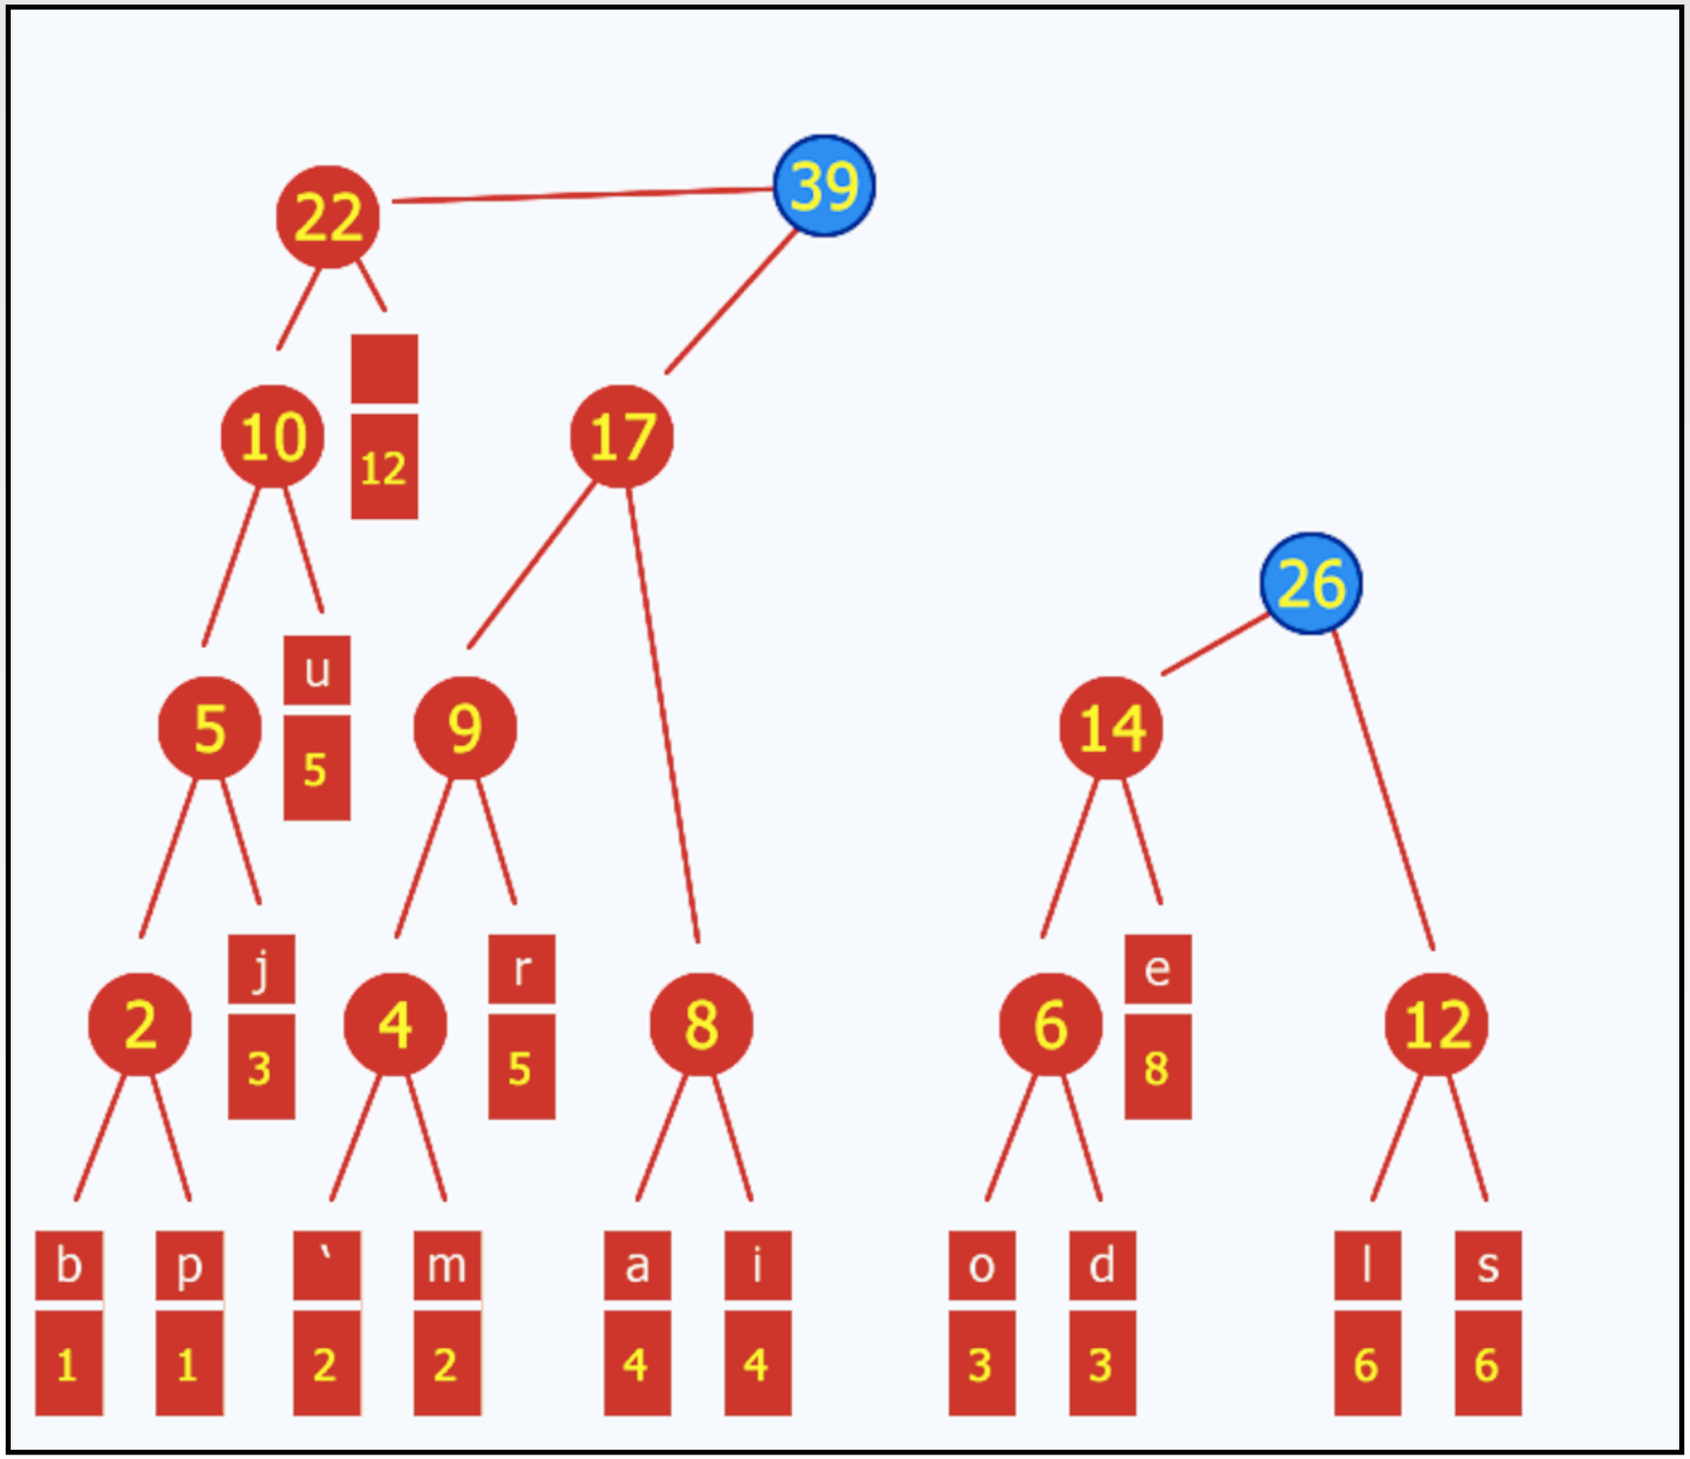

Árvore de Huffman

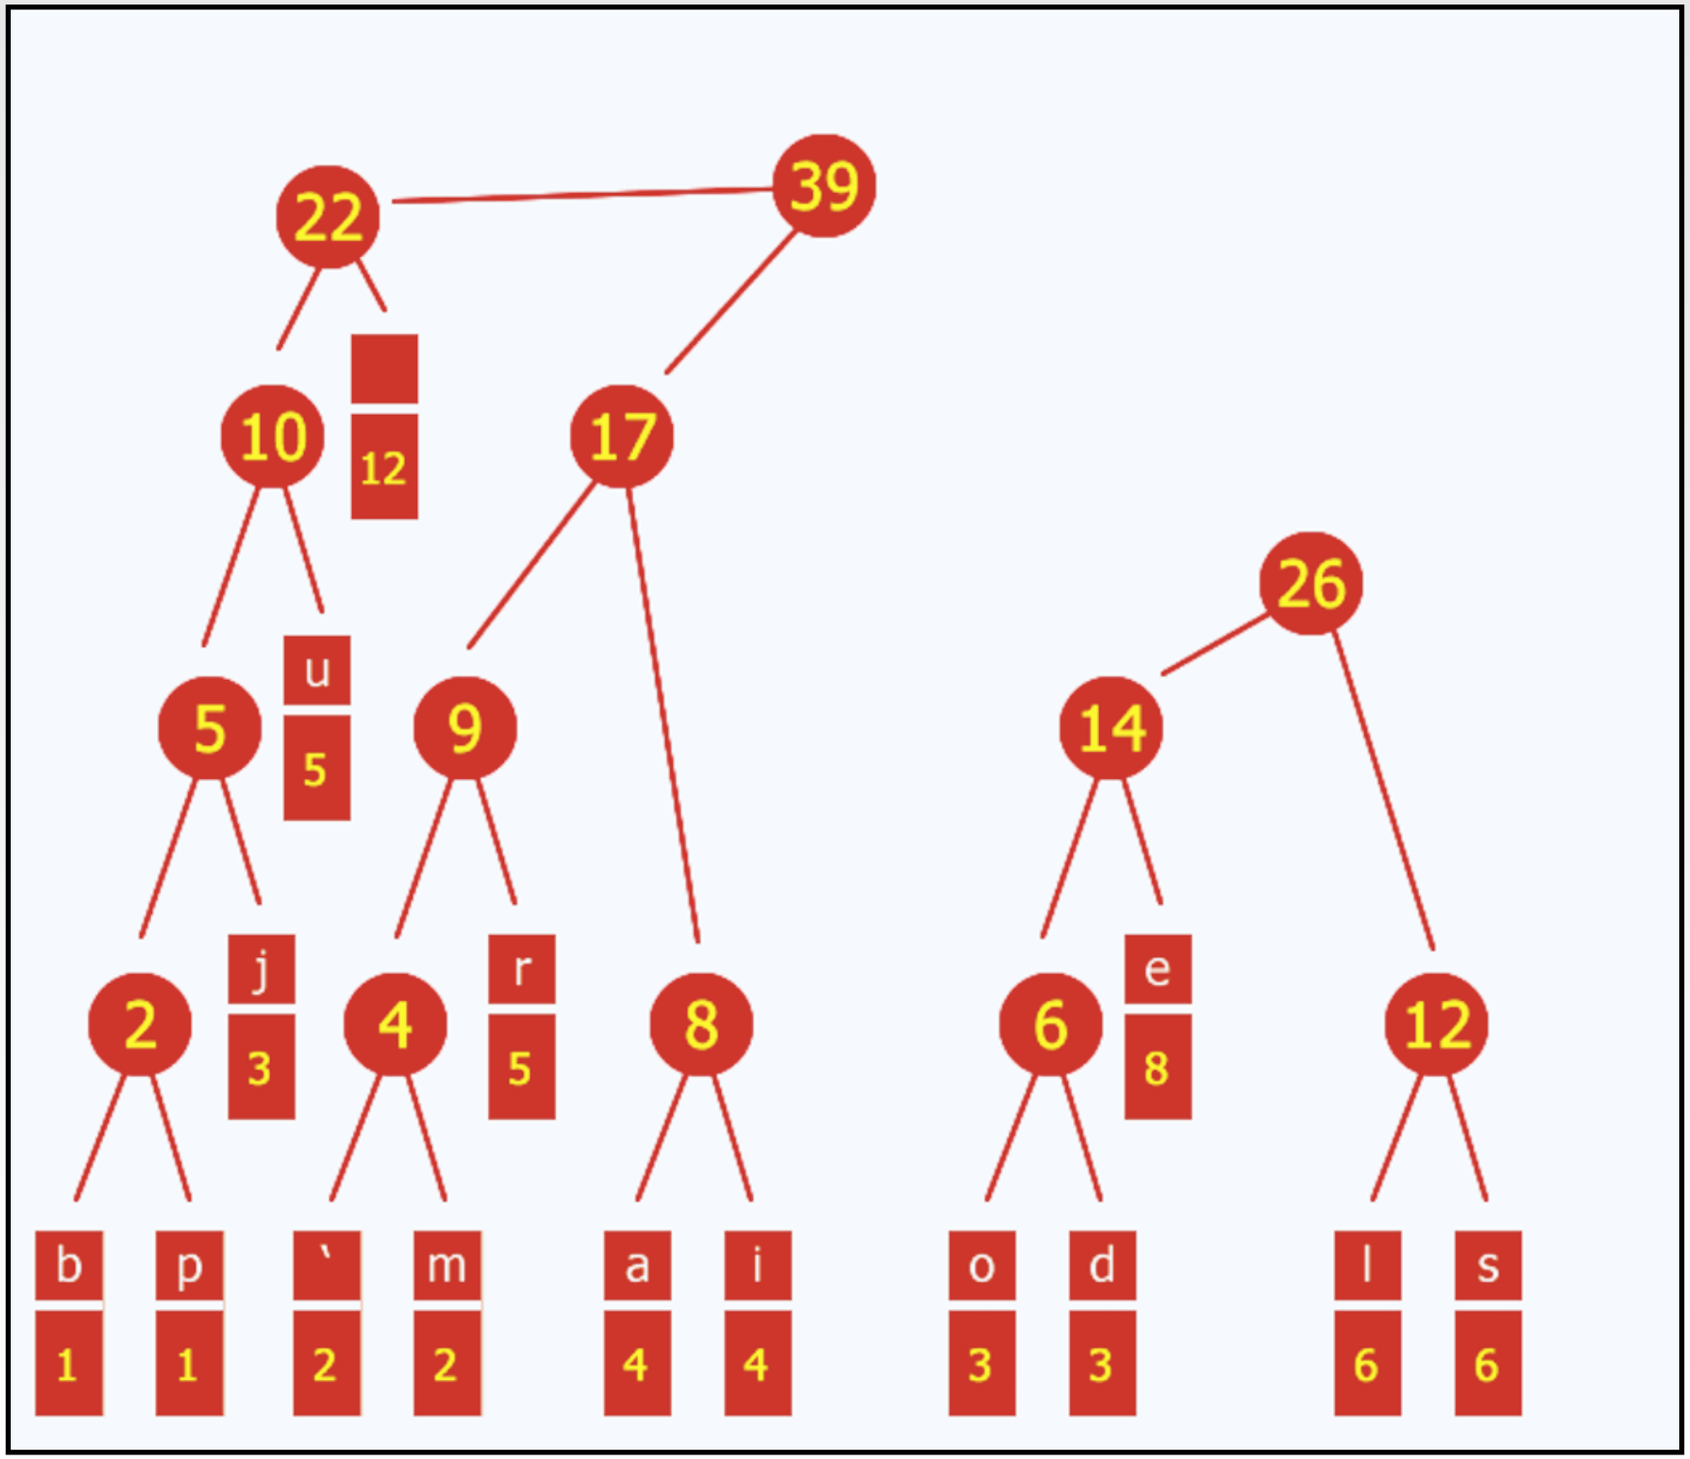

Árvore de Huffman

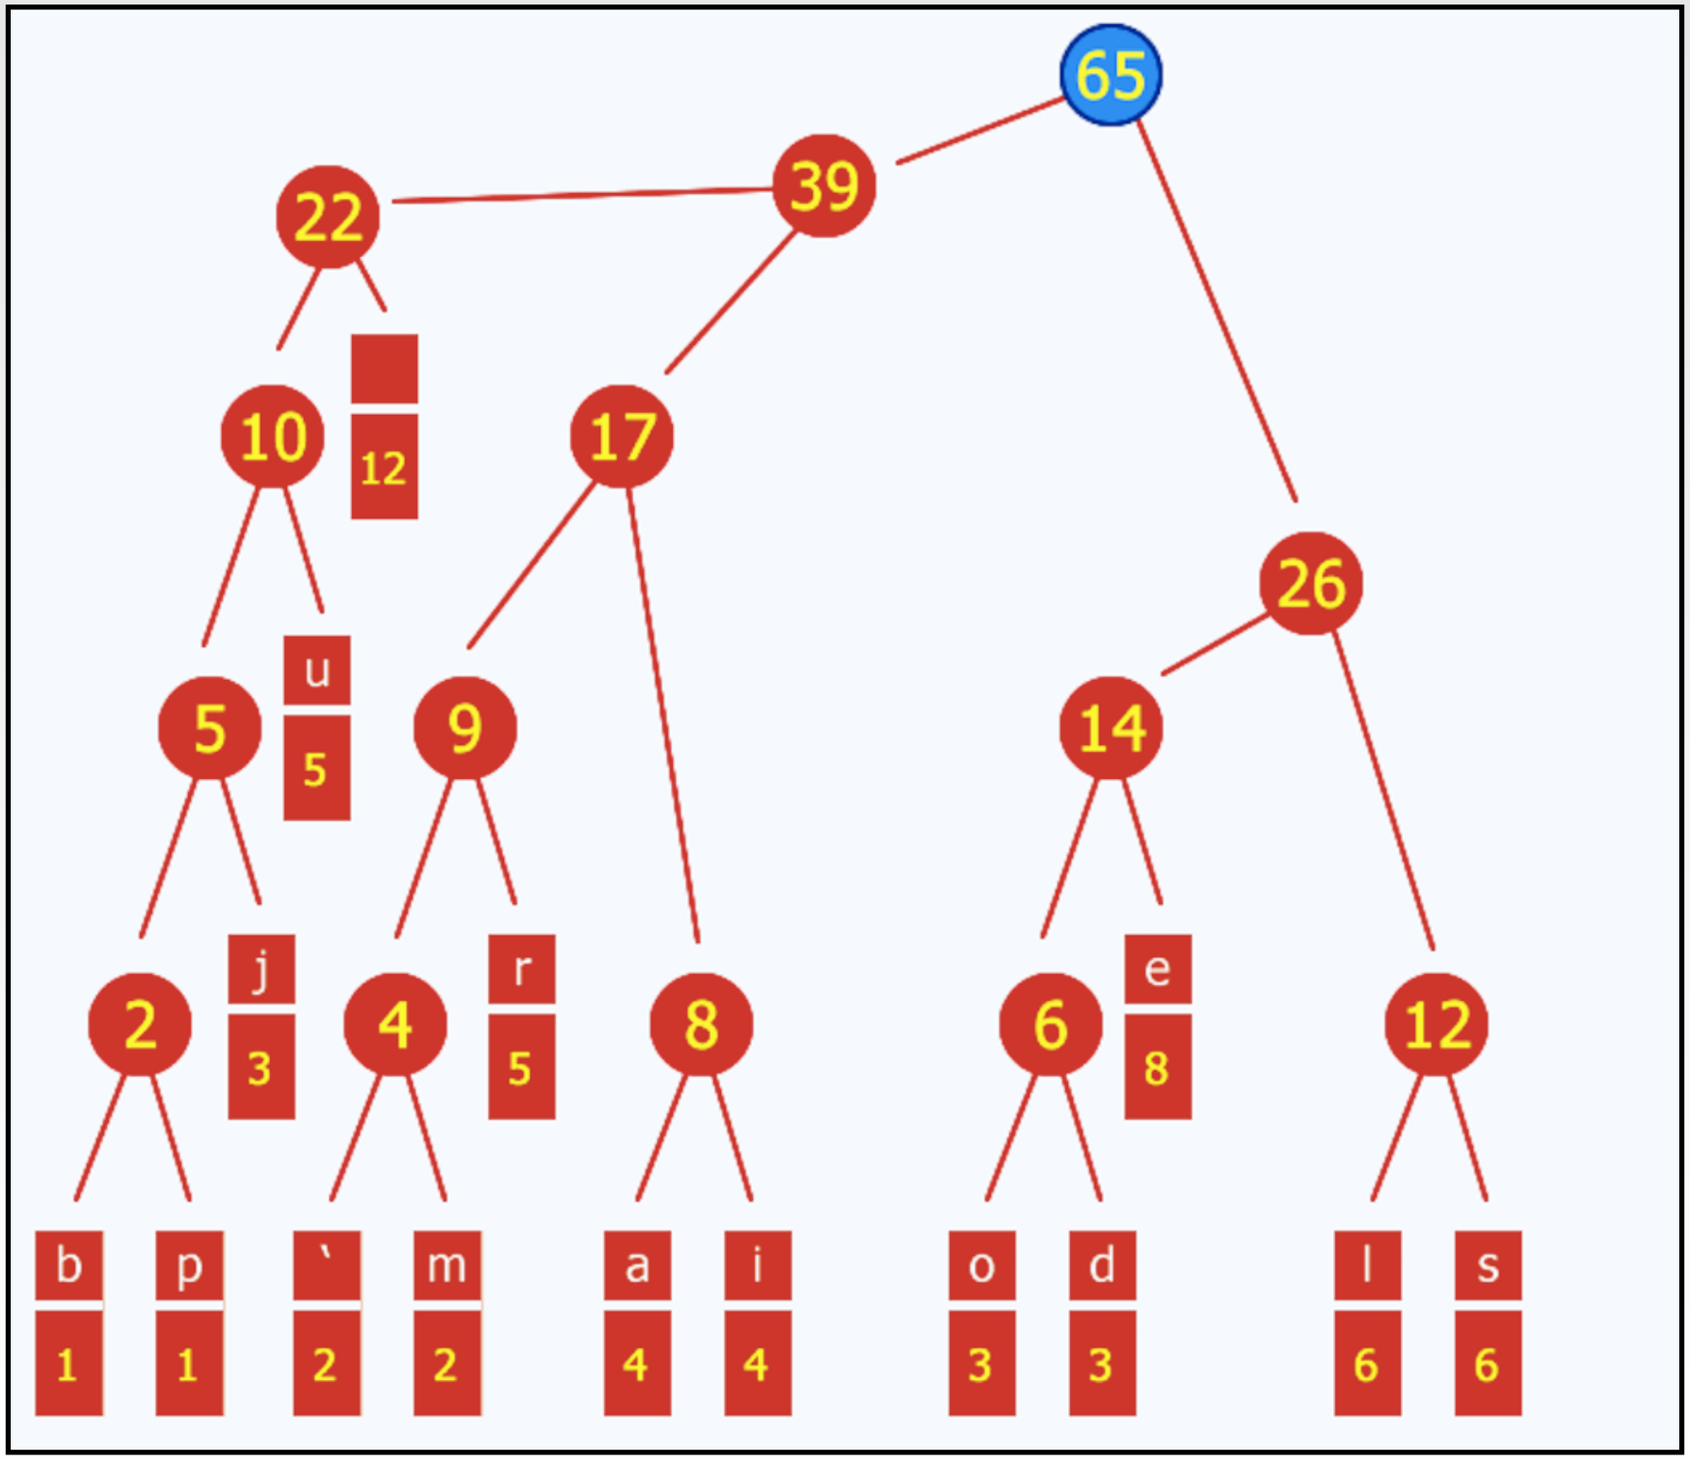

Árvore de Huffman

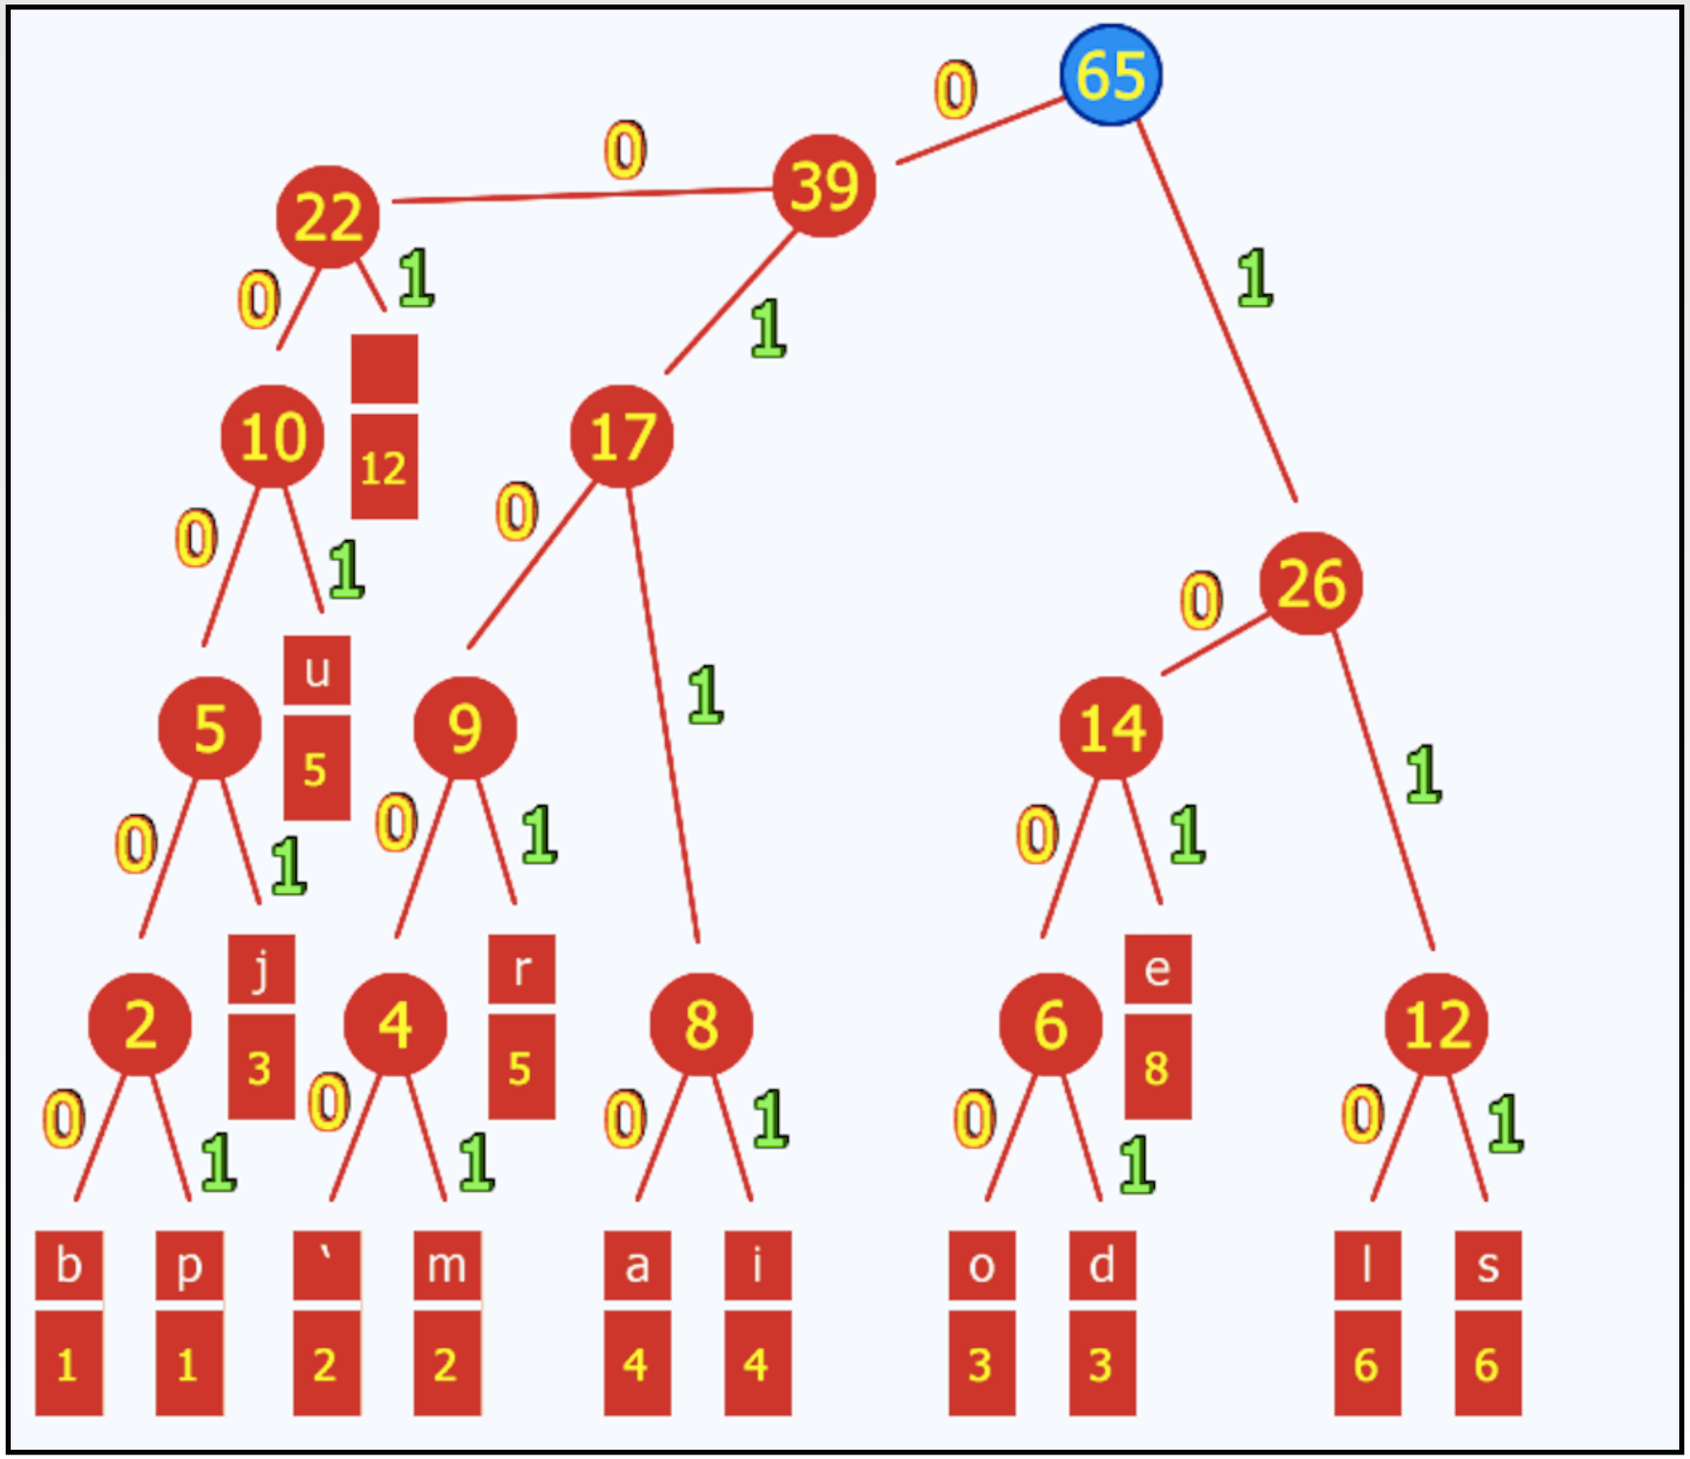

Algoritmo de Huffman

Input: a collection C of objects containing a character and its frequency.
Output: the root of a Huffman tree
Uses: priority queue Q
$n = |C|$
$Q = C$
for i=1 to n-1
    z = new treenode
    left(z) = ExtractMin(Q)
    right(z) = ExtractMin(Q)
    frequency(z) = frequency(left(z)) + frequency(right(z))
    Insert(Q, z)
return ExtractMin(Q)

Running time: $(O(n \lg n))$

Referências

- Histórico
- Notas de Aula (Prof. Leonardo Vidal)